



دانشکده مهندسی کامپیوتر

دسته‌بندی اشیای ترافیکی با استفاده از YOLO

۶ دسته متفاوت: عابر، تریلر، اتوبوس، خودروی سبک، وانت و موتور

پیاده‌سازی با معماری YOLOv11

استاد راهنما:

دکتر رضا شمسایی

استاد داور:

دکتر امیر باوفای طوسی


نام دانشجو:

محمد امیر صادق‌زاده

بخش ۱

صورت مسئله و مبانی نظری

مفاهیم پایه‌ای، مجموعه داده و مدل انتخاب شده



- مرجع [۱]: مجموعه داده چنددامنه رانندگی خود کار (IADD)

- دانشکده مهندسی خودرو دانشگاه علم و صنعت

- چاپ شده در مجله IET Image Processing در سال ۲۰۲۳

- هدف اصلی: بهبود توانایی تعمیم مدل های یادگیری عمیق


- پوشش شرایط شهری، برون شهری و جریان های ترافیکی مختلف

نسخه داده	تعداد تصویر	تعداد ویدیو
مجموعه منتشر شده	۹۷,۵۲۸	۱۷۱
بخش دارای برچسب	۸۳,۰۴۲	۱۶۶
زیرمجموعه نهایی	۳۷,۱۴۲	۱۶۰

- شش رده، هشت شهر و شرایط روز، شب، باران و هوای ابری
- استخراج تصویر از ویدیوهای ثبت شده؛ هر ۲ ثانیه یک فریم
- برچسب گذاری به صورت نیمه نظارتی با مدل YoloR
- ۱۴,۴۸۶ تصویر بخش آزمون، بدون برچسب بودند
- روش حل این مشکل در بخش ۲ بیان شده است


وضعیت	رده پروژه	رده مصوب
گسترده‌تر	شخص	عابر
یکسان	اتوبوس	اتوبوس
یکسان	خودروی سبک	خودروی سبک
یکسان	موتورسیکلت	موتور
ادغام در خودروی باری	خودروی باری	تریلر
ادغام در خودروی باری	خودروی باری	وانت
افزوده شد	چراغ راهنمایی	—

IoU = 0.11




انطباق ضعیف — رد می شود

IoU = 0.43



انطباق مرزی

IoU = 0.78



انطباق خوب — پذیرفته می شود

■ ناحیه اشتراک ■ کادر پیش بینی شده ■ کادر واقعی

$$IoU = \frac{area(B_{pred} \cap B_{gt})}{area(B_{pred} \cup B_{gt})}$$

- **IoU:** میزان انطباق کادر پیش بینی شده با کادر واقعی
- مقدار IoU همواره بین صفر و یک قرار می گیرد
- مقدار یک به معنی انطباق کامل و صفر به معنی نبود هم پوشانی است

امتیاز F1

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

- ❑ میانگین هماهنگ دقت و فراخوانی است
- ❑ فقط وقتی مقدار بالایی می گیرد که هر دو معیار مناسب باشند
- ❑ برای ارزیابی متعادل مدل استفاده می شود
- ❑ اگر یکی از دو معیار ضعیف باشد، F1 نیز کاهش می یابد

فراخوانی

$$\text{Recall} = \frac{TP}{TP + FN}$$

- ❑ نسبت اشیای درست شناسایی شده به کل اشیای واقعی
- ❑ نشان می دهد مدل چه مقدار از اشیای موجود را پیدا کرده است
- ❑ افزایش FN باعث کاهش فراخوانی می شود
- ❑ فراخوانی بالا یعنی اشیای کمتری از دست می روند

دقت

$$\text{Precision} = \frac{TP}{TP + FP}$$

- ❑ نسبت پیش بینی های مثبت صحیح به کل پیش بینی های مثبت
- ❑ نشان می دهد وقتی مدل یک شیء را تشخیص می دهد، چقدر قابل اعتماد است
- ❑ افزایش FP باعث کاهش دقت می شود
- ❑ دقت بالا یعنی خطاهای مثبت کاذب کمتر است

mAP@0.5:0.95

$$mAP@0.5:0.95 = \frac{1}{10} \sum_{j=1}^{10} mAP(IoU_j)$$

❑ معیار سخت گیرانه تر برای کیفیت مکان یابی کادرها

❑ میانگین mAP در ۱۰ آستانه IoU

❑ آستانه ها از ۰.۵۰ تا ۰.۹۵ با گام ۰.۰۵

❑ mAP (IoU_j): عملکرد مدل در آستانه IoU شماره j

mAP@0.5

$$mAP@0.5 = \frac{1}{N} \sum_{i=1}^N AP_i(0.5)$$

❑ میانگین AP همه رده ها در آستانه هم پوشانی ۰.۵

❑ پیش بینی صحیح: رده درست و آستانه هم پوشانی بیشتر از ۰.۵

❑ mAP@0.5 بالاتر = عملکرد بهتر مدل

دقت متوسط برای هر رده


$$AP = \int_0^1 P(r) dr$$

❑ محاسبه جداگانه برای هر رده

❑ بر پایه منحنی دقت-فراخوانی

❑ تعریف: مساحت زیر منحنی دقت-فراخوانی

❑ AP بیشتر = عملکرد بهتر



شکل ۱-۲: ساختار کلی معماری YOLOv11 و جایگاه بلوک‌ها در ستون فقرات، گردن و سر [۵]

بخش ۲

رفع چالش‌های مجموعه داده

حذف تصاویر معیوب، حل مشکل نشت اطلاعات و توزیع مجدد داده

چالش‌ها و مشکلات مجموعه داده IADD

فریم ۰ آموزش	فریم ۱ آموزش	فریم ۲ آزمون
فریم ۳ آموزش	فریم ۴ آزمون	فریم ۵ آزمون
فریم ۶ آموزش	فریم ۷ آموزش	فریم ۸ آموزش
فریم ۹ آموزش	فریم ۱۰ آموزش	فریم ۱۱ اعتبارسنجی

۱. نشت داده: فریم‌های یک ویدئو در چند بخش [۲]

۲. ویدیوهای تکراری: محتوای یکسان با دو شناسه

۳. برچسب معیوب: کادر ناقص، جابه‌جا یا غایب

۴. ناهم‌ترازی: تفاوت دشواری دو بخش ارزیابی


۵. آزمون بی‌برچسب: ساخت آزمون برچسب‌دار

این ترتیب فقط یک نمونه است؛

الگوی تقسیم در ویدیوهای مختلف

یکسان نیست.

نمونه واقعی از پراکندگی فریم‌های Record001_D



نتیجه بهترین دوره در هر یک از آموزش‌های انجام شده براساس معیار $mAP@0.5$

فرایند ساخت مجموعه داده نهایی



شکل ۱-۲: مراحل ساخت نسخه نهایی مجموعه داده از داده خام (بخش ۳-۲-۲)

بررسی ویدیوهای مشکوک

غربال اولیه

- ۱۳ ویدیو با میانگین دقت متوسط کمتر از ۶۳ ، ۰

بازبینی برچسب‌ها

- ویدیوی ۴۲۶: برچسب نادرست؛ امتیاز ۰، ۰۰۷
- ویدیوی ۴۶: برچسب ناقص؛ امتیاز ۰، ۴۵۱
- ۱۱ ویدیوی دشوار: حفظ

بررسی تکرار

- ۳ ویدیوی تکراری: حذف

مجموع حذف‌شده: ۵ ویدیو



نمونه برچسب نادرست در ویدیو شماره‌های ۴۶ و ۴۲۶

بخش	تعداد ویدیو	تعداد تصویر	سهم از کل تصاویر	تعداد نمونه	نمونه در تصویر
آموزش	۷۹	۲۶,۰۰۰	۷۰٪	۲۰۴,۰۰۹	۷,۸
اعتبارسنجی	۳۹	۵,۵۷۱	۱۵٪	۳۶,۸۱۰	۶,۶
آزمون	۴۲	۵,۵۷۱	۱۵٪	۳۴,۹۹۴	۶,۳

۲۷۵,۸۱۳ نمونه

۱۶۰ ویدیو

۳۷,۱۴۲ تصویر

پارامتر	مقدار
واحد تقسیم	ویدیو
سهم هدف تصاویر	۷۰، ۱۵، ۱۵ درصد
بذر تقسیم	۸۰
رده‌های کم نمونه	۲، ۳، ۵
معیار اولویت	شمار اشیای رده‌های ۲، ۳ و ۵
حجم آموزش	۲۶,۰۰۰ تصویر
حجم هر بخش ارزیابی	۵, ۵۷۱ تصویر
گروه‌بندی محیطی	روز، شب، باران، ابری


build_subset_v5.py

```


if rare_score(r) > 0:
    s = max(FRAC, key=lambda s: rt[s]-sr[s])
else:
    s = max(FRAC, key=lambda s: ft[s]-sf[s])
assign[r] = s

```

- ویدیوهای دارای رده کم نمونه: تخصیص بر اساس بیشترین کمبود رده‌های نادر
- سایر ویدیوها: تخصیص بر اساس بیشترین کمبود تعداد فریم
- هدف: نزدیک کردن هم‌زمان توزیع رده‌ها و اندازه بخش‌ها به هدف



درصد از نمونه‌ها



آموزش اعتبارسنجی آزمون

توزیع اندازه اشیا

compute_v5_validity.py

SMALL, LARGE = 0.01, 0.06

a = float(q[3]) * float(q[4])

if a < SMALL:

size[0] += 1


elif a >= LARGE:

size[2] += 1

else:

size[1] += 1

توزیع شرایط محیطی در سه بخش



توزیع شرایط محیطی

compute_v5_validity.py

```
S = {s: analyze(s) for s in SPLITS}
counts = Counter()
for s in SPLITS:
    counts.update(S[s]["cond"])
total = sum(counts.values())
for c, n in counts.items():
    print(c, round(100*n/total, 1))
```



شرایط محیطی	تعداد تصاویر	سهم از کل تصاویر
روز	۳۰,۰۶۷	۸۱,۰٪
شب	۳,۲۸۵	۸,۸٪
باران	۳,۲۷۶	۸,۸٪
آبری	۵۱۴	۱,۴٪

بخش ۳

آموزش و پیکربندی نهایی مدل

مقایسه آموزش‌های انجام‌شده، بررسی ابرپارامترها، بهینه‌سازها و کد هسته آموزش



نتیجه بهترین دوره در هر یک از آموزش‌های انجام شده براساس معیار $mAP@0.5$


پارامتر	مقدار
معماری	YOLOv11s
اندازه ورودی	۱۲۸۰
اندازه دسته	۱۲
بهینه‌ساز	AdamW
نرخ یادگیری اولیه	۰,۰۰۱
زمان بند	کسینوسی
بیشینه دوره آموزش	۱۵۰
توقف زودهنگام	۱۰

IADD_YOLOv11_Colab_run8.ipynb

```
model = YOLO('yolo11s.pt')
model.train(data='iadd_subset_v5/data.yaml',
            epochs=150, patience=10, imgsz=1280, batch=12,
            optimizer='AdamW', lr0=0.001, cos_lr=True,
            mixup=0.1, hsv_v=0.4, degrees=5.0)
```

- آغاز از وزن‌های از پیش آموزش دیده COCO
- انتخاب بهترین وزن با اعتبارسنجی
- ارزیابی آزمون پس از پایان تنظیمات

آزمایش مقایسه‌ای انتخاب بهینه‌ساز



- عوامل متغیر: نوع بهینه‌ساز و زمان‌بند
- پیکربندی ۱: SGD + زمان‌بند خطی
- پیکربندی ۲: AdamW + زمان‌بند کسینوسی
- شرایط آموزش و افزایش داده یکسان
- عملکرد بهتر AdamW در اعتبارسنجی و آزمون

نتیجه: AdamW + Cosine


به عنوان پیکربندی برنده انتخاب شد

بخش ۴

بررسی نتایج و جمع‌بندی

نمایش نمودارها و تصاویر خروجی، نتیجه‌گیری و پیشنهادات برای پژوهش‌های آینده

ارزیابی نهایی روی بخش آزمون




♦ , ۸۷۴

mAP@0.5

♦ , ۷۰۷


mAP@0.5:0.95

عملکرد به تفکیک رده



- بهترین عملکرد: خودروی سبک
- موتورسیکلت با وجود کم نمونه بودن، عملکرد خوبی دارد
- ضعیف ترین رده: اتوبوس، به ویژه از نظر فراخوانی
- علت ضعف اتوبوس: کم بودن نمونه و شباهت ظاهری به خودروی باری
- چراغ راهنمایی تحت تأثیر کوچک بودن اندازه شیء قرار گرفته است
- عملکرد وابسته به تعداد نمونه، اندازه شیء و شباهت بصری بین رده ها است

ماتریس درهم ریختگی




- بیشترین خطا بین اتوبوس و خودروی باری
- بخشی از چراغ‌های راهنمایی به صورت پس‌زمینه تشخیص داده شده‌اند
- چالش‌های اصلی: شباهت ظاهری رده‌ها و اشیای کوچک

آستانه اطمینان بهینه: ۰,۴۰۶


خروجی مدل






برجسب واقعی



خروجی مدل



برجسب واقعی



چراغ راهنمایی خودروی باری اتوبوس موتورسیکلت خودروی سبک شخص

روز و شب

باران و هوای ابری

نتیجه گیری

- نتایج مدل نهایی YOLOv11s روی آزمون:
 - میانگین دقت متوسط در آستانه هم پوشانی ۵, ۰ = ۸۷۴, ۰
 - میانگین دقت متوسط در بازه آستانه های هم پوشانی ۵, ۰ تا ۹۵, ۰ = ۷۰۷, ۰
- اصلاح ساختار مجموعه داده و جلوگیری از نشت داده نقش مهم تری از تغییر بهینه ساز داشت
- چالش های اصلی: اشیای کوچک، شباهت اتوبوس با خودروی باری و نبود برخی نمونه ها

پیشنهاد برای پژوهش های آینده

- تکمیل و بهبود برچسب ها و افزایش تنوع نمونه های اتوبوس و خودروی باری
- بررسی جداگانه اثر بهینه ساز، نرخ یادگیری و زمان بند با چند بذر تصادفی
- ارزیابی مدل روی مجموعه داده مستقل برای سنجش تعمیم پذیری



با سپاس از توجه شما

پرسش و پاسخ

- [۱] Khosravian, A., Amirkhani, A., Masih-Tehrani, M., and Yazdaniyoo, A., *Multi-domain autonomous driving dataset: Towards enhancing the generalization of the convolutional neural networks in new environments*, IET Image Processing, vol. 17, no. 4, 2023, pp. 1253-1266.
- [۲] Kaufman, S., Rosset, S., Perlich, C., and Stitelman, O., *Leakage in Data Mining: Formulation, Detection, and Avoidance*, ACM Transactions on Knowledge Discovery from Data, vol. 6, no. 4, 2012, article 15.
- [۵] Sapkota, R., Flores-Calero, M., Qureshi, R., Badgujar, C., Nepal, U., Poullose, A., Zeno, P., Vaddevolu, U. B. P., Khan, S., Shoman, M., Yan, H., and Karkee, M., *YOLO advances to its genesis: a decadal and comprehensive review of the You Only Look Once (YOLO) series*, Artificial Intelligence Review, vol. 58, no. 9, 2025, article 274.
- [۹] Lin, J., Wang, P., Ruan, Y., and Sun, Y., *YOLO11-WLBS: an efficient model for pavement defect detection*, Scientific Reports, vol. 16, article 5284, 2026.