



پایان نامه دوره کارشناسی مهندسی کامپیوتر

موضوع:

دسته بندی اشیای ترافیکی (شش دسته متفاوت عابر،
تریلر، اتوبوس، خودروی سبک، وانت، موتور) با
استفاده از YOLO

استاد راهنما:

دکتر رضا شمسایی

نام دانشجو:

محمد امیر صادق زاده

شهریور ۱۴۰۵

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ



پایان نامه دوره کارشناسی مهندسی کامپیوتر

موضوع:

دسته بندی اشیای ترافیکی (شش دسته متفاوت عابر،
تریلر، اتوبوس، خودروی سبک، وانت، موتور) با
استفاده از YOLO

استاد راهنما:

دکتر رضا شمسایی

استاد داور:

دکتر امیر باوفای طوسی

نام دانشجو:

محمد امیر صادق زاده

شهریور ۱۴۰۵

سپاسگزاری

از استاد راهنمای گرامی ام، جناب دکتر شمسایی، که در تمام مراحل این پروژه، از طرح مسئله تا نگارش نهایی، با راهنمایی‌های دقیق و شکیبایی بسیار مرا همراهی کردند، صمیمانه سپاسگزارم. همچنین از استادان گروه مهندسی کامپیوتر که در سال‌های تحصیل، دانش و تجربه خود را بی‌دریغ در اختیارم گذاشتند، و از خانواده‌ام که پشتیبان همیشگی من بوده‌اند، قدردانی می‌کنم.

تقدیم به

جویندگان دانش

که آموختن را پایانی نمی‌دانند

چکیده

دسته‌بندی اشیای ترافیکی (شش دسته متفاوت عابر، تریلر، اتوبوس، خودروی سبک،

وانت، موتور) با استفاده از YOLO

در این پژوهش، یک آشکارساز اشیای ترافیکی بر پایه معماری YOLOv11 روی مجموعه داده رانندگی IADD آموزش داده شد و ارزیابی گردید. از آنجا که تصاویر این مجموعه از فریم‌های پیاپی ویدیو استخراج شده‌اند، پیش از آموزش چهار اشکال شناسایی و رفع گردید: امکان نشت داده میان بخش‌های آموزش و ارزیابی، وجود ویدیوهای تکراری با شناسه متفاوت، ویدیوهایی با برجسب معیوب و ناهم‌ترازی دشواری دو بخش ارزیابی. تقسیم داده در سطح کل ویدیو، همراه با هم‌ترازی توزیع اندازه اشیاء، رده‌ها و شرایط محیطی انجام شد. سپس دو راهبرد بهینه‌سازی در شرایط یکسان مقایسه و پیکربندی برتر انتخاب گردید. مدل نهایی روی بخش آزمون به میانگین دقت متوسط ۰٫۸۷۴ در آستانه هم‌پوشانی ۰٫۵ دست یافت. تحلیل نتایج به تفکیک رده نشان داد که عملکرد مدل بیش از آنکه صرفاً به تعداد نمونه‌ها وابسته باشد، تحت تأثیر میزان شباهت بصری و اندازه اشیاء قرار دارد.

واژه‌های کلیدی

آشکارسازی اشیای ترافیکی، YOLOv11، مجموعه داده IADD، تقسیم‌بندی در سطح ویدیو، نشت داده،

اعتبارسنجی داده، میانگین دقت متوسط.

فهرست مطالب

صفحه	عنوان
۱.....	مقدمه
۳.....	فصل یکم - مروری بر پیشینه و مبانی نظری
۳.....	۱-۱- مقدمه
۴.....	۱-۲- تشخیص اشیا و جایگاه آن در رانندگی خود کار
۵.....	۱-۳- روش های مبتنی بر یادگیری عمیق در تشخیص اشیا
۵.....	۱-۳-۱- روش های دومرحله ای
۶.....	۱-۳-۲- روش های یک مرحله ای
۷.....	۱-۳-۳- سیر تکامل خانواده YOLO
۷.....	۱-۳-۴- معماری YOLOv11
۱۰.....	۱-۳-۵- افزایش داده

۱۲	۴-۱- معیارهای ارزیابی آشکارسازهای اشیا
۱۲	۴-۱-۱- نسبت هم‌پوشانی
۱۳	۴-۱-۲- دقت و فراخوانی
۱۴	۴-۱-۳- امتیاز F1
۱۴	۴-۱-۴- دقت متوسط و میانگین دقت متوسط
۱۶	۵-۱- مجموعه داده‌های حوزه رانندگی خودکار
۱۶	۵-۱-۱- مجموعه داده‌های شاخص
۱۶	۵-۱-۲- مجموعه داده IADD
۱۸	۶-۱- چالش‌های عملی در آموزش آشکارساز روی داده‌های ویدیویی
۱۸	۶-۱-۱- نشت داده در مجموعه داده‌های ویدیو محور
۱۸	۶-۱-۲- عدم توازن رده‌ها
۱۹	۶-۱-۳- تشخیص اشیای کوچک
۲۰	۶-۱-۴- نویز برجسب
۲۰	۷-۱- جمع‌بندی
۲۱	فصل دوم - روش تحقیق، داده و ابزارها
۲۱	۲-۱- مدل انتخابی
۲۲	۲-۲- مجموعه داده
۲۲	۲-۲-۱- معرفی مجموعه داده
۲۴	۲-۲-۲- چالش‌های مجموعه داده
۲۶	۲-۲-۳- ساخت نسخه نهایی داده
۲۸	۲-۲-۴- اعتبارسنجی توزیع داده

۳۲	۳-۲- افزایش داده
۳۳	۴-۲- محیط پیاده‌سازی
۳۴	۵-۲- پیکربندی آموزش
۳۷	۶-۲- روش ارزیابی
۳۸	۷-۲- جمع‌بندی
۳۹	فصل سوم - اجرا، آزمایش‌ها و نتایج
۳۹	۱-۳- روند آموزش و همگرایی
۴۱	۲-۳- آزمایش مقایسه‌ای انتخاب بهینه‌ساز
۴۳	۳-۳- نتایج کمی مدل نهایی
۴۳	۱-۳-۳- معیارهای کلی
۴۳	۲-۳-۳- نتایج به تفکیک رده
۴۶	۳-۳-۳- منحنی دقت و فراخوانی
۴۶	۴-۳-۳- ماتریس درهم‌ریختگی
۴۸	۴-۳- نتایج کیفی
۵۱	۵-۳- جمع‌بندی
۵۲	فصل چهارم - بحث، نتیجه‌گیری و پیشنهادها
۵۲	۱-۴- تفسیر یافته‌های اصلی
۵۲	۱-۱-۴- اعتبار ارزیابی در تقسیم‌بندی ویدیومحور داده
۵۳	۱-۲-۴- اثر تفکیک‌پذیری ورودی بر تشخیص اشیای کوچک
۵۴	۱-۳-۴- مقایسه راهبردها

- ۵۴..... ۴-۱-۴- تحلیل عملکرد مدل در رده‌های مختلف
- ۵۵..... ۴-۱-۵- نقش کیفیت برچسب در تحلیل خطا
- ۵۶..... ۴-۲- جایگاه نتایج در مقایسه با پژوهش‌های پیشین
- ۵۷..... ۴-۳- دامنه اعتبار نتایج و محدودیت‌های اجرایی
- ۵۷..... ۴-۳-۱- دامنه داده و ارزیابی
- ۵۷..... ۴-۳-۲- طراحی آزمایش‌های مقایسه‌ای
- ۵۷..... ۴-۳-۳- منابع محاسباتی و انتخاب مقیاس مدل
- ۵۸..... ۴-۳-۴- پوشش و کیفیت برچسب‌ها
- ۵۸..... ۴-۴- نتیجه‌گیری
- ۵۹..... ۴-۵- پیشنهاد برای پژوهش‌های آینده
- ۶۰..... مراجع و منابع

فهرست شکل‌ها

عنوان

صفحه

- شکل ۱-۱: مقایسه ساختار روش‌های دومرحله‌ای و یک‌مرحله‌ای در تشخیص اشیا (بخش ۲-۳-۱)..... ۶
- شکل ۲-۱: ساختار کلی معماری YOLOv11 و جایگاه بلوک‌ها در ستون فقرات، گردن و سر (بخش ۴-۳-۱)..... ۸
- شکل ۳-۱: مفهوم نسبت هم‌پوشانی میان کادر پیش‌بینی‌شده و کادر واقعی (بخش ۱-۴-۱)..... ۱۳
- شکل ۱-۲: مراحل ساخت نسخه نهایی مجموعه داده از داده خام (بخش ۳-۲-۲)..... ۲۷
- شکل ۲-۲: سهم هر رده از نمونه‌های هر بخش (محور عمودی لگاریتمی) (بخش ۴-۲-۲)..... ۲۹
- شکل ۳-۲: توزیع اندازه اشیا در سه بخش مجموعه داده (بخش ۴-۲-۲)..... ۳۰
- شکل ۴-۲: توزیع شرایط محیطی در سه بخش مجموعه داده (محور عمودی لگاریتمی) (بخش ۴-۲-۲)..... ۳۱
- شکل ۱-۳: روند تغییرات خطا و میانگین دقت متوسط در طول آموزش (بخش ۱-۳)..... ۴۰
- شکل ۲-۳: مقایسه دو راهبرد بهینه‌سازی روی بخش‌های اعتبارسنجی و آزمون (بخش ۲-۳)..... ۴۲

شکل ۳-۳: معیار $AP@0.5$ و امتیاز F1 به تفکیک رده روی بخش آزمون (بخش ۳-۳-۲) ۴۴

شکل ۴-۳: منحنی دقت و فراخوانی مدل نهایی روی بخش آزمون (بخش ۳-۳-۳) ۴۶

شکل ۵-۳: ماتریس درهم‌ریختگی نرمال‌سازی‌شده مدل نهایی روی بخش آزمون (بخش ۳-۳-۴) ۴۷

شکل ۶-۳: مقایسه برچسب واقعی و خروجی مدل در شرایط روز و شب (بخش ۳-۴) ۴۹

شکل ۷-۳: مقایسه برچسب واقعی و خروجی مدل در شرایط باران و روز ابری (بخش ۳-۴) ۵۰

فهرست جدول‌ها

عنوان

صفحه

جدول ۱-۱: مشخصات کلی مجموعه داده IADD.....	۱۷
جدول ۱-۲: حجم بخش‌های مجموعه داده نهایی.....	۲۷
جدول ۲-۲: شمار نمونه هر رده در بخش‌های مختلف.....	۲۸
جدول ۳-۲: توزیع اندازه اشیا در بخش‌های مختلف (درصد).....	۲۹
جدول ۴-۲: توزیع شرایط محیطی در بخش‌های مختلف (درصد).....	۳۱
جدول ۵-۲: پیکربندی نهایی آموزش مدل.....	۳۴
جدول ۱-۳: معیارهای کلی مدل نهایی.....	۴۳
جدول ۲-۳: معیارهای مدل نهایی به تفکیک رده روی بخش آزمون.....	۴۴

لیست علائم و اختصارات

ADAS	سامانه‌های کمک‌راننده پیشرفته
AdamW	بهینه‌ساز آدام با کاهش وزن تفکیک‌شده
AP	دقت متوسط
BDD100K	مجموعه داده رانندگی برکلی
C2PSA	بلوک پیچشی با توجه مکانی موازی
C3K2	بلوک پیچشی متقاطع با هسته کوچک
CNN	شبکه عصبی پیچشی
COCO	مجموعه داده اشیای متداول در بستر
F1	امتیاز هماهنگی دقت و فراخوانی
FN	منفی نادرست
FP	مثبت نادرست
GPU	پردازنده گرافیکی
IADD	مجموعه داده رانندگی خودکار ایران

IoU	نسبت هم پوشانی
KITTI	مجموعه داده کیتی
mAP	میانگین دقت متوسط
R-CNN	شبکه عصبی پیچشی مبتنی بر ناحیه
SGD	گرایان کاهش تصادفی
SPPF	ادغام هرمی مکانی سریع
SSD	آشکارساز تک گذر چند کادره
TP	مثبت درست
YOLO	تو فقط یک بار نگاه می کنی

مقدمه

خودروهای خودران و سامانه‌های کمک‌راننده پیشرفته، برای هر تصمیمی که می‌گیرند به یک پیش‌نیاز وابسته‌اند: آنکه بدانند در صحنه پیش رو چه چیزهایی وجود دارد و هر یک کجا قرار گرفته است. این شناخت از طریق وظیفه‌ای به نام تشخیص اشیا فراهم می‌شود و خروجی آن، ورودی مستقیم ماژول‌های تصمیم‌گیری و کنترل خودرو است. از این رو، هر خطا در این مرحله، در تمام مراحل بعدی تکثیر می‌شود و می‌تواند به تصمیمی نادرست و در نهایت به تصادف بینجامد [۱]. مسئله‌ای که این پروژه به آن می‌پردازد، ساخت و ارزیابی صادقانه یک آشکارساز اشیای ترافیکی برای صحنه‌های رانندگی در ایران است.

دشواری این مسئله تنها به انتخاب یک مدل مناسب محدود نمی‌شود. مدل‌های تشخیص اشیا در دامنه‌ای که روی آن آموزش دیده‌اند عملکرد خوبی دارند؛ اما با تغییر دامنه، دقتشان به شدت افت می‌کند. الگوی ترافیکی، نوع وسایل نقلیه و شکل علائم راهنمایی در ایران با کشورهای که مجموعه داده‌های مرجع این حوزه در آن‌ها گردآوری شده‌اند تفاوت دارد؛ بنابراین، آموزش مدل بر روی داده‌های خارجی، عملکرد مناسبی در صحنه‌های رانندگی ایران به همراه نخواهد داشت [۱].

اهمیت این موضوع دو وجه دارد؛ وجه نخست، کاربردی است: تشخیص درست شخص، موتورسیکلت و چراغ راهنمایی در نواحی شهری، پیش‌شرط هر سامانه ایمنی خودرو است و کیفیت آن مستقیماً با جان انسان‌ها سروکار دارد [۱]. وجه دوم، روش‌شناختی است. داده‌های این حوزه از فریم‌های پیاپی ویدیو ساخته می‌شوند و اگر این ویژگی در طراحی ارزیابی نادیده گرفته شود، عددی که گزارش می‌شود می‌تواند به‌طور مصنوعی بالا برود، بی‌آنکه مدل واقعاً بهتر شده باشد [۲]. چنین عددی نه قابل استناد است و نه قابل مقایسه. به همین سبب، هدف این مطالعه رساندن نتایج به بالاترین مقدار ممکن نبوده، بلکه رسیدن به عددی بوده که بتوان به آن استناد کرد.

در این پروژه، نسخه یازدهم خانواده YOLO روی مجموعه داده رانندگی خودکار ایران آموزش داده شد؛ مجموعه‌ای که شش رده متداول شهری را در بر می‌گیرد. پیش از آن، چهار اشکال در داده خام شناسایی و برطرف شد: امکان نشت داده میان بخش‌های آموزش و ارزیابی، ویدیوهای تکراری با شناسه متفاوت، برچسب‌های معیوب و ناهم‌ترازی دشواری دو بخش ارزیابی و آزمون. سپس دو راهبرد بهینه‌سازی در شرایط یکسان مقایسه شدند تا پیکربندی نهایی بر پایه شواهد تجربی انتخاب شود. مدل نهایی روی بخش آزمون به مقدار ۰٫۸۷۴ mAP@0.5 دست یافت.

ساختار این پایان‌نامه چنین است: فصل نخست به پیشینه و مبانی نظری می‌پردازد و مسئله، معماری مدل و معیارهای ارزیابی را معرفی می‌کند؛ فصل دوم روش کار، مجموعه داده و پیکربندی آموزش را چنان شرح می‌دهد که قابل بازتولید باشد؛ فصل سوم نتایج کمی و کیفی را ارائه می‌کند؛ و فصل چهارم به بحث درباره این نتایج، محدودیت‌ها، نتیجه‌گیری و پیشنهادهایی برای ادامه کار اختصاص دارد.

فصل یکم - مروری بر پیشینه و مبانی نظری

۱-۱- مقدمه

هدف این فصل، فراهم کردن زمینه علمی لازم برای درک روش پیشنهادی و نتایج این پروژه است. بدین منظور، نخست مسئله تشخیص اشیا^۱ و جایگاه آن در سامانه‌های رانندگی خودکار تعریف می‌شود؛ سپس دو خانواده اصلی روش‌های مبتنی بر یادگیری عمیق^۲ در این حوزه معرفی و مقایسه می‌گردند و معماری مدل مورد استفاده در این پروژه به تفصیل شرح داده می‌شود. در ادامه، معیارهای متداول ارزیابی آشکارساز اشیا^۳ به همراه روابط ریاضی آن‌ها ارائه می‌شود؛ زیرا تفسیر درست نتایج فصل سوم بدون شناخت این معیارها ممکن نیست. آنگاه مجموعه داده‌های شاخص این حوزه و به‌طور خاص، مجموعه داده مورد استفاده در این پروژه معرفی می‌شوند و سرانجام، چالش‌های عملی که در جریان این پروژه با آن‌ها روبه‌رو شدیم و راهکارهای موجود برای هر یک مرور می‌گردد.

^۱ Object Detection

^۲ Deep Learning

^۳ Object Detector

۱-۲- تشخیص اشیا و جایگاه آن در رانندگی خودکار

تشخیص اشیا یکی از مسائل بنیادین بینایی ماشین^۱ است که هدف آن، هم‌زمان تعیین «نوع» و «موقعیت» تمام اشیای موجود در یک تصویر است. مدلی که این کار را انجام می‌دهد آشکارساز اشیا نامیده می‌شود. برخلاف مسئله طبقه‌بندی تصویر^۲ که تنها یک برچسب برای کل تصویر پیش‌بینی می‌کند، در تشخیص اشیا برای هر شیء یک کادر محدودکننده^۳ به‌همراه برچسب رده و درجه اطمینان پیش‌بینی می‌شود [۳]. از این‌رو، تشخیص اشیا را می‌توان ترکیبی از دو زیرمسئله مکان‌یابی و طبقه‌بندی دانست.

در سامانه‌های کمک‌راننده پیشرفته^۴ و خودروهای خودران^۵، ماژول بینایی وظیفه دارد اشخاص، موتورسیکلت‌ها، اتوبوس‌ها، خودروهای باری، خودروهای سبک و چراغ‌های راهنمایی را در زمان واقعی و با دقت بالا شناسایی کند؛ چراکه خروجی این ماژول ورودی مستقیم ماژول‌های تصمیم‌گیری و کنترل وسایل نقلیه است و هر خطای تشخیص می‌تواند به تصمیم نادرست و در نهایت به تصادف منجر شود [۱]. دو الزام کلیدی در این کاربرد وجود دارد: نخست «دقت کافی»، به‌ویژه برای اشیای کوچک و دور؛ دوم «سرعت پردازش بالا» تا امکان اجرای بلادرنگ روی سخت‌افزار محدود خودرو فراهم باشد. همین دو الزام است که انتخاب معماری مدل را در این حوزه محدود می‌کند.

^۱ Machine Vision

^۲ Image Classification

^۳ Bounding Box

^۴ Advanced Driver Assistance Systems (ADAS)

^۵ Autonomous Vehicles (AVs)

۱-۳- روش‌های مبتنی بر یادگیری عمیق در تشخیص اشیا

پیش از ظهور یادگیری عمیق، روش‌های تشخیص اشیا بر ویژگی‌های دست‌ساز و طبقه‌بندهای سنتی استوار بودند و کارایی محدودی داشتند. با معرفی شبکه‌های عصبی پیچشی^۱ و رشد توان محاسباتی، روش‌های مبتنی بر یادگیری عمیق به سرعت جایگزین آن‌ها شدند و امروزه به دو خانواده اصلی تقسیم می‌شوند [۳].

۱-۳-۱- روش‌های دومرحله‌ای

در خانواده روش‌های دومرحله‌ای^۲، فرایند تشخیص دو مرحله مجزا دارد: در مرحله نخست، مجموعه‌ای از نواحی کاندید که احتمال وجود شیء در آن‌ها بالاست، تولید می‌شود و در مرحله دوم، هر ناحیه کاندید طبقه‌بندی شده و مختصات کادر آن اصلاح می‌گردد. شبکه عصبی پیچشی مبتنی بر ناحیه^۳ و نسخه‌های بهبودیافته آن، شناخته‌شده‌ترین نمایندگان این خانواده هستند. مزیت اصلی این روش‌ها دقت بالا و ضعف اصلی آن‌ها سرعت پایین است؛ زیرا هزینه محاسباتی مرحله دوم به تعداد نواحی کاندید وابسته است و همین امر کاربرد آن‌ها را در سامانه‌های بلادرنگ^۴ دشوار می‌کند [۳]. شناخته‌شده‌ترین نماینده این خانواده، معماری فستر آر-سی‌ان‌ان^۵ است که در آن، خود شبکه عصبی وظیفه تولید نواحی کاندید را بر عهده می‌گیرد و بدین ترتیب سرعت مرحله نخست به طور چشمگیری افزایش می‌یابد [۳].

^۱ Convolutional Neural Networks

^۲ Two-stage Detectors


^۳ Region-based Convolutional Neural Network

^۴ Real-time

^۵ Faster R-CNN

۱-۳-۲- روش‌های یک‌مرحله‌ای

در مقابل، روش‌های یک‌مرحله‌ای^۱ بخش تولید نواحی کاندید را حذف می‌کنند و رده و مختصات کادر همه اشیاء را در یک عبور مستقیم از شبکه پیش‌بینی می‌نمایند. این رویکرد نخستین‌بار در معماری «تو فقط یک‌بار نگاه می‌کنی»^۲ معرفی شد [۴]. در این معماری، تصویر ورودی به یک شبکه مشبک تقسیم می‌شود و هر خانه از شبکه مسئول پیش‌بینی اشیایی است که مرکزشان درون آن خانه قرار دارد. حذف مرحله پیشنهاد ناحیه، سرعت را چند برابر افزایش می‌دهد و به همین دلیل روش‌های یک‌مرحله‌ای گزینه غالب در کاربردهای بلادرنگ، از جمله خودروهای خودران هستند. در نسخه‌های نخستین، دقت این روش‌ها به‌ویژه برای اشیای کوچک، پایین‌تر از روش‌های دو مرحله‌ای بود؛ اما پیشرفت‌های معماری در نسل‌های بعدی این فاصله را تا حد زیادی از میان برداشت [۵]. نمونه شاخص دیگر این خانواده، آشکارساز تک‌گذر چندکادره^۳ است که پیش‌بینی را هم‌زمان روی چند نقشه ویژگی با تفکیک‌پذیری متفاوت انجام می‌دهد تا اشیاء در مقیاس‌های گوناگون بهتر تشخیص داده شوند [۳]. شکل (۱-۱) تفاوت ساختاری این دو خانواده را در کنار هم نشان می‌دهد.



شکل ۱-۱: مقایسه ساختار روش‌های دو مرحله‌ای و یک مرحله‌ای در تشخیص اشیاء (بخش ۱-۳-۲)

^۱ One-stage Detectors

^۲ You Only Look Once (YOLO)

^۳ Single Shot MultiBox Detector (SSD)

۱-۳-۳- سیر تکامل خانواده YOLO

از زمان معرفی نسخه نخست، خانواده YOLO نسل‌های متعددی را پشت سر گذاشته و در هر نسل، بهبودهایی در ساختار ستون فقرات، گردن و سر شبکه و نیز در راهبردهای آموزش آن، اعمال شده است. از جمله تحولات مهم این مسیر می‌توان به معرفی روش‌های نوین افزایش داده^۱، بهینه‌سازی فرایند آموزش در نسخه چهارم [۵] و سپس حرکت تدریجی این خانواده به سمت معماری‌های بدون لنگر^۲ اشاره کرد. تفاوت کلیدی این معماری‌ها با نسل‌های پیشین، آن است که در آن‌ها به جای تطبیق پیش‌بینی‌ها با مجموعه‌ای از کادرهای مرجع از پیش تعریف شده، مختصات کادر به صورت مستقیم پیش‌بینی می‌شود؛ این تغییر، فرایند آموزش را ساده‌تر و تعداد ابرپارامتر^۳ها را کمتر می‌کند [۵]. مرور جامعی که اخیراً بر یک دهه تحول این خانواده انجام شده است، نشان می‌دهد روند کلی این معماری‌ها به سمت افزایش دقت بوده است؛ درحالی که بار محاسباتی تنها افزایش اندکی داشته است [۵].

۱-۳-۴- معماری YOLOv11

مدل مورد استفاده در این پروژه، نسخه تشخیص اشیای YOLOv11 است. معماری این مدل، مانند دیگر مدل‌های جدید خانواده YOLO، از سه بخش پیوسته تشکیل می‌شود: ستون فقرات^۴ برای استخراج نگاشت‌های ویژگی از تصویر ورودی، گردن^۵ برای آمیختن اطلاعات این نگاشت‌ها در مقیاس‌های گوناگون، و سر^۶ برای

^۱ Data Augmentation

^۲ Anchor-free

^۳ Hyperparameter


^۴ Backbone

^۵ Neck

^۶ Head

تولید پیش‌بینی نهایی کادر و دسته شیء. این تقسیم‌بندی، مسیر پردازش تصویر را از استخراج ویژگی‌های اولیه تا پیش‌بینی خروجی مشخص می‌کند [۵، ۶].

مطابق پیکربندی رسمی YOLO11، ستون فقرات با پنج لایه پیچشی کاهنده آغاز می‌شود و در سه سطح P3/8، P4/16 و P5/32 نگاشت ویژگی تولید می‌کند. عدد پس از خط تیره، نسبت کوچک شدن طول و عرض نگاشت ویژگی نسبت به تصویر ورودی را نشان می‌دهد؛ بنابراین شاخه P3/8 جزئیات مکانی بیشتری دارد و شاخه‌های P4/16 و P5/32 زمینه دید وسیع‌تری فراهم می‌کنند. در مسیر بالا به پایین گردن شبکه، اطلاعات معنایی استخراج شده در لایه‌های عمیق‌تر به نگاشت‌هایی با تفکیک‌پذیری بالاتر منتقل می‌شود. سپس با مسیر پایین به بالا، اطلاعات مکانی را دوباره به سطوح عمیق‌تر بازمی‌گرداند. سه نگاشت حاصل به سر آشکارساز داده می‌شوند؛ همان سه خروجی‌ای که در شکل ۱-۲ با برجسب‌های "دیکت" نمایش یافته‌اند [۵، ۶].



شکل ۱-۲: ساختار کلی معماری YOLOv11 و جایگاه بلوک‌ها در ستون فقرات، گردن و سر (بخش ۱-۳-۴)

نخستین تفاوت ساختاری YOLOv11 با YOLOv8، جایگزینی بلوک C2f با C3K2 در ستون فقرات و گردن است. C3K2 گونه‌ای از بلوک‌های اتصال جزئی میان‌مرحله‌ای^۱ است که واحد تکرارشونده درون آن، بسته به مقیاس مدل، از ساختار گلوگاه^۲ یا C3K استفاده می‌کند. هدف این جایگزینی، پردازش کارآمدتر ویژگی‌ها و کنترل هزینه محاسباتی، در عین حفظ مسیرهای انتقال ویژگی در ساختار CSP است [۶].

پس از آخرین بلوک C3K2 در مسیر استخراج ویژگی، بلوک SPPF قرار دارد که در این نوشتار «ادغام هرمی مکانی سریع» نامیده می‌شود. در پیکربندی رسمی YOLOv11، این بلوک پیش از نخستین عمل بزرگ‌نمایی در مسیر ادغام چندمقیاسی تعریف شده است؛ بنابراین در مرز انتقال ویژگی‌ها از ستون فقرات به گردن قرار می‌گیرد. یک عمل بیشینه‌گیری 5×5 را سه بار پیاپی اجرا و خروجی‌های میانی را با ورودی اولیه ترکیب می‌کند. حاصل این کار، گردآوری ویژگی‌ها در چند مقیاس است؛ اما با محاسبه‌ای کم‌هزینه‌تر از اجرای مستقل چند هسته بزرگ. این بلوک در YOLOv8 نیز وجود دارد و جزء تازه‌ای در YOLOv11 نیست [۵، ۶].

تغییر دوم، افزوده‌شدن بلوک C2PSA بلافاصله پس از SPPF است. این بلوک نیز پیش از نخستین عمل بزرگ‌نمایی قرار دارد و خروجی آن وارد مسیر ادغام چندمقیاسی گردن می‌شود. C2PSA بخشی از کانال‌های ورودی را از یک مسیر توجه مکانی عبور می‌دهد و سپس آن را با مسیر میان‌بر ترکیب می‌کند. درون مسیر توجه مکانی، سازوکار توجه چندسری^۳ و یک شبکه پیش‌خور کانولوشنی^۴ به کار می‌روند تا وابستگی میان نواحی تصویر در نگاشت ویژگی مدل‌سازی شود. بنابراین C2PSA اطلاعات ناحیه‌ای را پیش از ورود به گردن شبکه پالایش می‌کند. این سازوکار در YOLOv8 وجود ندارد [۶].

^۱ Cross Stage Partial (CSP)

^۲ Bottleneck

^۳ Multi-head Attention

^۴ Convolutional Feed-Forward Network

سومین تفاوت در بخش آشکارساز رخ می‌دهد: شاخه طبقه‌بندی YOLOv11 با پیچش‌های تفکیک‌پذیر عمقی^۱ سبک‌تر شده است. با وجود این تغییر، منطق خروجی نسبت به YOLOv8 حفظ شده است؛ سر شبکه بدون لنگر است و دو مسیر جداگانه برای برآورد مکان کادر و طبقه‌بندی دارد. مکان کادر با روش DFL مدل‌سازی می‌شود و سه خروجی چندمقیاسی برای آشکارسازی اشیای کوچک، متوسط و بزرگ به کار می‌روند. در نتیجه، تفاوت‌های YOLOv11 با YOLOv8 تنها به ستون فقرات محدود نیست و شامل بلوک‌های ویژگی، توجه و شاخه طبقه‌بندی سر نیز می‌شود [۶].

این معماری در پنج مقیاس n ، s ، m ، l و x عرضه می‌شود که با تغییر ضرایب عمق و عرض شبکه، میان تعداد پارامترها، بار محاسباتی و دقت مبادله ایجاد می‌کنند. در این پروژه، مقیاس کوچک، یعنی YOLOv11s، انتخاب شد؛ زیرا نسخه آموزش‌دیده آن برای شش رده مورد مطالعه حدود ۹.۴ میلیون پارامتر دارد و با حافظه پردازنده گرافیکی در دسترس سازگار بود. دلیل انتخاب مقیاس کوچک، محدودیت سخت‌افزاری پروژه است؛ این انتخاب به معنای برتری ذاتی این مقیاس در همه کاربردها نیست [۶].

۱-۳-۵- افزایش داده

افزایش داده، مجموعه‌ای از تبدیل‌های تصادفی است که هنگام آموزش بر تصاویر ورودی اعمال می‌شود تا شبکه در هر گام، نمونه‌ای کمی متفاوت ببیند و به جای حفظ کردن تصاویر، الگوهای کلی را بیاموزد. در کنار تبدیل‌های ساده، مانند وارونگی و تغییر روشنایی، دو تبدیل ترکیبی در خانواده YOLO نقش برجسته‌ای یافته‌اند که به جای تغییر یک تصویر، چند تصویر را با هم می‌آمیزند [۶].

^۱ Depthwise Separable Convolution

نخستین آن‌ها موزاییک^۱ است که در نسخه چهارم این خانواده معرفی شد [۵]. در این روش، چهار تصویر آموزشی در یک قاب واحد کنار هم چیده می‌شوند و کادرهای هر چهار تصویر، با تصحیح مختصات، به قاب حاصل منتقل می‌گردند. اثر آن دوگانه است: شبکه در هر گام با زمینه‌های متنوع‌تری روبه‌رو می‌شود و چون هر تصویر به یک چهارم قاب فشرده می‌گردد، اشیاء در مقیاس‌های کوچک‌تری نیز دیده می‌شوند. همین ویژگی دوم است که موزاییک را برای تشخیص اشیاء کوچک سودمند می‌کند.

تبدیل دوم، ترکیب وزنی^۲ است که در مرجع [۷] معرفی شد. در این روش، دو تصویر با وزن‌های مکمل روی هم نشانده می‌شوند؛ یعنی هر پیکسل تصویر حاصل، میانگین وزن‌دار همان پیکسل از دو تصویر است و نتیجه، صحنه‌ای نیمه‌شفاف شامل هر دو عکس می‌باشد. در کاربرد طبقه‌بندی، برچسب دو تصویر نیز با همان وزن‌ها میانگین گرفته می‌شود؛ اما در پیاده‌سازی برای تشخیص اشیاء، کادرهای هر دو تصویر در کنار یکدیگر نگه داشته می‌شوند، به گونه‌ای که مدل باید همه آن‌ها را در تصویر ترکیبی بیابد [۶].

هر دو تبدیل نمونه‌هایی می‌سازند که در دنیای واقعی وجود ندارند. سودشان آن است که مدل را با شرایط دشوار هم‌پوشانی و مقیاس کوچک آشنا می‌کنند و از بیش‌برازش می‌کاهند. خطرشان آن است که اگر برچسب تصاویر مبدأ خطا داشته باشد، آن خطا نیز به نمونه ترکیبی راه می‌یابد. انتخاب شدت هر یک در فصل دوم، با توجه به همین بده‌بستان انجام شده است [۵، ۷].

^۱ Mosaic

^۲ Mixup

۱-۴- معیارهای ارزیابی آشکارسازهای اشیا

ارزیابی یک آشکارساز اشیا پیچیده‌تر از ارزیابی یک طبقه‌بند ساده است؛ زیرا علاوه بر درستی برچسب رده، باید میزان انطباق کادر پیش‌بینی‌شده با کادر واقعی نیز سنجیده شود. در این بخش، معیارهای استاندارد این حوزه که در فصل سوم برای گزارش نتایج به کار رفته‌اند، معرفی می‌شوند.


۱-۴-۱- نسبت هم‌پوشانی

پایه همه معیارهای تشخیص اشیا، سنجه نسبت هم‌پوشانی^۱ است که میزان انطباق کادر پیش‌بینی‌شده و کادر واقعی را اندازه می‌گیرد و بر اساس رابطه (۱-۱) محاسبه می‌شود [۵]:

$$IoU = \frac{\text{area}(B_{\text{pred}} \cap B_{\text{gt}})}{\text{area}(B_{\text{pred}} \cup B_{\text{gt}})} \quad (1-1)$$

در این رابطه، صورت کسر مساحت اشتراک دو کادر و مخرج آن مساحت اجتماع دو کادر است. مقدار این سنجه همواره بین صفر و یک قرار دارد؛ یک به معنای انطباق کامل و صفر به معنای نبود هرگونه هم‌پوشانی می‌باشد. برای آنکه یک پیش‌بینی «درست» به‌شمار آید، باید هم برچسب رده آن صحیح باشد و هم مقدار نسبت هم‌پوشانی آن از یک آستانه مشخص فراتر رود. آستانه متداول در این حوزه، مقدار ۰٫۵ است [۳، ۵]. در ادامه، شکل (۱-۳) این سنجه را به صورت تصویری نمایش می‌دهد.

^۱ Intersection over Union (IoU)



شکل ۳-۱: مفهوم نسبت هم‌پوشانی میان کادر پیش‌بینی‌شده و کادر واقعی (بخش ۱-۴-۱)

۱-۴-۲- دقت و فراخوانی

با مقایسه پیش‌بینی‌های مدل با کادرهای واقعی و در نظر گرفتن آستانه نسبت هم‌پوشانی، پیش‌بینی‌ها در قالب یکی از سه دسته مثبت درست^۱، مثبت نادرست^۲ و منفی نادرست^۳ قرار می‌گیرد. با استفاده از این سه کمیت، دو معیار دقت و فراخوانی طبق روابط (۲-۱) و (۳-۱) تعریف می‌شوند [۵]:

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2-1)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (3-1)$$

دقت بیانگر نسبت پیش‌بینی‌های صحیح مدل به مجموع پیش‌بینی‌های مثبت آن است؛ در مقابل، فراخوانی نشان می‌دهد چه نسبتی از اشیای موجود در تصویر توسط مدل شناسایی شده‌اند. میان این دو معیار یک بده‌بستان ذاتی وجود دارد [۸]: افزایش آستانه اطمینان، دقت را بالا و فراخوانی را پایین می‌برد و کاهش آن اثر معکوس

^۱ True Positive (TP)

^۲ False Positive (FP)

^۳ False Negative (FN)

دارد. از این رو، گزارش هیچ یک از این دو به تنهایی معنادار نیست و باید به صورت یک منحنی و در سراسر بازه آستانه بررسی شوند.

۱-۴-۳- امتیاز F1

برای خلاصه کردن این بده‌بستان در یک عدد واحد، از امتیاز F1 استفاده می‌شود که میانگین هماهنگ دقت و فراخوانی است و بر اساس رابطه (۴-۱) محاسبه می‌گردد [۵]:

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (4-1)$$

میانگین هماهنگ به گونه‌ای است که مقدار بالای آن تنها در صورت بالا بودن هم‌زمان هر دو معیار دقت و فراخوانی حاصل می‌شود. بنابراین مدلی که یکی از دو معیار را فدای دیگری کرده باشد، امتیاز بالایی کسب نمی‌کند. از آنجا که مقدار این امتیاز به آستانه اطمینان وابسته است، در فصل سوم آستانه کاری مدل، نقطه‌ای در نظر گرفته شده است که این امتیاز روی داده اعتبارسنجی بیشینه می‌شود.

۱-۴-۴- دقت متوسط و میانگین دقت متوسط

معیار اصلی و استاندارد برای ارزیابی آشکارسازهای اشیاء، میانگین دقت متوسط^۱ است. برای محاسبه این معیار، ابتدا منحنی دقت بر حسب فراخوانی برای هر رده رسم می‌شود. مساحت زیر این منحنی، دقت متوسط^۲ آن رده را مطابق رابطه (۵-۱) نشان می‌دهد [۹]:

$$AP = \int_0^1 P(r) dr \quad (5-1)$$

^۱ mean Average Precision (mAP)

^۲ Average Precision (AP)

در این رابطه، $P(r)$ مقدار دقت در سطح فراخوانی r برای رده مورد ارزیابی است.

در تشخیص اشیا، درست بودن یک پیش‌بینی افزون بر برچسب رده، به میزان هم‌پوشانی کادر پیش‌بینی شده با کادر واقعی وابسته است. این هم‌پوشانی با معیار IoU سنجیده می‌شود. در نماد $AP_i(0.5)$ ، زیرنویس i رده مورد ارزیابی و عدد 0.5 آستانه نسبت هم‌پوشانی است؛ بنابراین پیش‌بینی زمانی مثبت درست محسوب می‌شود که رده آن صحیح و مقدار IoU دست کم 0.5 باشد. میانگین $AP_i(0.5)$ روی N رده، معیار $mAP@0.5$ را مطابق رابطه (۶-۱) به دست می‌دهد [۹]:

$$mAP@0.5 = \frac{1}{N} \sum_{i=1}^N AP_i(0.5) \quad (6-1)$$

معیار سخت‌گیرانه‌تر $mAP@0.5:0.95$ است. این معیار از میانگین دقت متوسط در ده آستانه هم‌پوشانی

0.50 تا 0.95 با گام 0.05 به دست می‌آید و مطابق رابطه (۷-۱) محاسبه می‌شود [۹]:

$$mAP@0.5:0.95 = \frac{1}{N} \sum_{i=1}^N \left(\frac{1}{10} \sum_{j=1}^{10} AP_i(IoU_j) \right) \quad (7-1)$$

در رابطه (۷-۱)، IoU_j آستانه شماره j است که از 0.5 آغاز می‌شود و در هر گام 0.05 افزایش می‌یابد؛

همچنین $AP_i(IoU_j)$ دقت متوسط رده i در همان آستانه را نشان می‌دهد. در نتیجه، عدد یا بازه پس از علامت @

آستانه هم‌پوشانی را مشخص می‌کند و با آستانه اطمینان تفاوت دارد. معیار $mAP@0.5$ عملکرد مدل را در

آستانه 0.5 می‌سنجد؛ $mAP@0.5:0.95$ نیز با میانگین‌گیری در چند آستانه، کیفیت مکان‌یابی کادرها را

سخت‌گیرانه‌تر ارزیابی می‌کند. در این پروژه هر دو معیار گزارش شده‌اند.

۱-۵- مجموعه داده‌های حوزه رانندگی خودکار

۱-۵-۱- مجموعه داده‌های شاخص

کیفیت و تنوع مجموعه داده آموزشی، تأثیری چشمگیر بر توانایی تعمیم مدل دارد. در حوزه عمومی تشخیص اشیاء، مجموعه داده COCO به عنوان مرجع استاندارد شناخته می‌شود که شامل بیش از سیصد هزار تصویر در هشتاد رده شیء است و پروتکل ارزیابی آن به معیار رایج این حوزه تبدیل شده است [۱۰]. در حوزه خاص رانندگی خودکار نیز مجموعه داده‌هایی نظیر KITTI، سیتی اسکپس^۱ و BDD100K معرفی شده‌اند. با این حال، چنان‌که در مرجع [۱] اشاره شده است، بسیاری از این مجموعه داده‌ها دامنه محدودی دارند و مدل‌های آموزش دیده روی آن‌ها، هنگام مواجهه با محیط‌هایی متفاوت از دامنه آموزش خود، افت کارایی محسوسی را تجربه می‌کنند. این مسئله برای کشورهایی با الگوی ترافیکی متفاوت اهمیت دوچندان می‌یابد.

۱-۵-۲- مجموعه داده IADD

مجموعه داده مورد استفاده در این پروژه، "مجموعه رانندگی خودکار ایران" نام دارد. مرجع [۱] مقاله مرتبط با آن می‌باشد و با هدف بهبود توانایی تعمیم شبکه‌های عمیق در محیط‌های جدید گردآوری شده است. این مجموعه ۹۷۰۵۲۸ تصویر را شامل می‌شود که از ۱۷۱ ویدیوی ضبط شده در شهرهای مختلف ایران استخراج شده‌اند و شش رده شیء را پوشش می‌دهند: شخص، خودروی سبک، موتورسیکلت، اتوبوس، خودروی باری و چراغ راهنمایی. ویژگی‌های متمایزکننده این مجموعه برشمرده عبارت‌اند از: تنوع بالای شرایط زمانی و جوی، شامل روز، شب، صبح، عصر و باران؛ تنوع محیطی شامل خیابان‌های شهری، بزرگراه‌ها و مسیرهای برون‌شهری و روستایی؛ استفاده از چندین دوربین دوربین با تفکیک‌پذیری‌های متفاوت به منظور کاهش وابستگی مدل به یک

^۱ Cityscapes

دوربین خاص؛ و حفظ عامدانه برخی تصاویر مات، با این استدلال که شبکه باید بتواند در شرایط واقعی و در حضور لرزش دوربین نیز عملکرد قابل اتکایی داشته باشد.

در مرجع [۱]، برای کاهش زمان و هزینه، برچسب‌گذاری به صورت نیمه نظارتی انجام شده است. ابتدا حدود ۳۰,۰۰۰ تصویر به صورت دستی برچسب‌گذاری و مدلی با آن‌ها آموزش داده شد؛ سپس مدل برای تصاویر باقی مانده برچسب تولید کرد و خروجی‌ها به صورت انسانی بازبینی و اصلاح شدند. این روش امکان تولید مجموعه‌ای بزرگ را فراهم کرد، اما می‌تواند مقداری نویز در برچسب‌ها باقی بگذارد؛ موضوعی که در بخش ۱-۶-۴ و فصل دوم بررسی می‌شود. تصاویر نیز با نرخ نیم فریم بر ثانیه از ویدیوها استخراج و برچسب‌ها در قالب YOLO ارائه شده‌اند [۱]. مشخصات کلی مجموعه داده در جدول (۱-۱) آمده است.

جدول ۱-۱: مشخصات کلی مجموعه داده IADD

ویژگی	مقدار
شمار تصاویر	۹۷,۵۲۸
شمار ویدیوهای منبع	۱۷۱
شمار رده‌ها	۶
شمار شهرهای گردآوری	۸
تفکیک‌پذیری تصاویر	۲۱۶۰×۳۸۴۰ تا ۴۸۰×۶۴۰
تقسیم آموزش / اعتبارسنجی / آزمون	۱۴,۸٪ / ۷,۲٪ / ۷۸٪
شیوه برچسب‌گذاری	نیمه نظارتی با بازبینی کارشناس

۱-۶- چالش‌های عملی در آموزش آشکارساز روی داده‌های ویدیویی

افزون بر انتخاب معماری، مجموعه‌ای از چالش‌های عملی وجود دارند که اگر نادیده گرفته شوند، می‌توانند نتایج گزارش شده را غیرقابل اتکا سازند. از آنجا که بخش عمده‌ای از کار انجام شده در این پروژه به شناسایی و رفع همین چالش‌ها اختصاص یافته است، در این بخش به اختصار به آن پرداخته می‌شود.

۱-۶-۱- نشت داده در مجموعه داده‌های ویدیو محور

مجموعه داده‌های این حوزه از فریم‌های ویدیو ساخته می‌شوند و فریم‌هایی که در یک ویدیو نزدیک به هم قرار دارند، عملاً یک صحنه‌اند: همان خیابان، همان وسایل نقلیه و همان زاویه دوربین، تنها با اندکی جابه‌جایی. اگر تقسیم داده به بخش‌های آموزش، اعتبارسنجی و آزمون در سطح تصویر انجام شود، فریم‌های یک ویدیوی واحد میان هر سه بخش پراکنده می‌شوند. آنگاه مدل در زمان ارزیابی تصویری را می‌بیند که نمونه‌ای تقریباً یکسان با آن را پیش‌تر در آموزش دیده است؛ یعنی به‌جای توانایی تعمیم، حافظه‌اش سنجیده می‌شود. این پدیده نشت داده^۱ نام دارد و معیارهای گزارش شده را به‌طور مصنوعی بالا می‌برد [۲]. نشت داده می‌تواند تصویری خوش‌بینانه و نادرست از کارایی واقعی مدل را ایجاد کند.

این مسئله در مورد استفاده عملاً وجود دارد؛ زیرا در تقسیم‌بندی اولیه، فریم‌های بسیاری از ویدیوها میان بخش‌های آموزش، اعتبارسنجی و آزمون توزیع شده‌اند. راهکار مناسب، تقسیم داده در سطح کل ویدیو است تا تمام فریم‌های هر ویدیو تنها در یکی از این سه بخش قرار گیرند. تقسیم‌بندی این پروژه نیز بر همین مبنا بازسازی شد و جزئیات آن در فصل دوم آمده است.

^۱ Data Leakage

۱-۶-۲- عدم توازن رده‌ها

در داده‌های واقعی ترافیکی، فراوانی رده‌ها به شدت نامتوازن است؛ برای نمونه، تعداد خودروهای سبک در یک صحنه شهری معمولاً چند صد برابر تعداد اتوبوس‌هاست. این عدم توازن دو پیامد دارد: نخست آنکه مدل در جریان آموزش، سیگنال کمتری برای یادگیری رده‌های کم‌نمونه دریافت می‌کند و دقت آن‌ها پایین‌تر می‌ماند؛ و دوم آنکه در زمان ارزیابی، شمار اندک نمونه‌های آزمون آن‌ها موجب می‌شود معیار محاسبه‌شده واریانس بالایی داشته باشد و کمتر قابل‌اتکا باشد [۱۱]. نکته دیگر آنکه میانگین دقت متوسط، میانگینی بدون وزن روی رده‌هاست؛ بنابراین کم‌نمونه‌ترین و پر‌نمونه‌ترین رده، سهم برابری در عدد نهایی دارند [۱۰].

۱-۶-۳- تشخیص اشیای کوچک

یافتن اشیای کوچک، یکی از دشوارترین جنبه‌های مسئله تشخیص اشیا به‌شمار می‌رود [۳]. اشیای کوچک پیکسل‌های کمتری را اشغال می‌کنند و در نتیجه، ویژگی‌های بصری کمتری برای استخراج در اختیار شبکه قرار می‌دهند؛ افزون بر این، در لایه‌های عمیق‌تر شبکه، وضوح مکانی نگاشت ویژگی کاهش می‌یابد. بنابراین، احتمال از دست رفتن کامل اطلاعات آن‌ها وجود دارد. در صحنه‌های ترافیکی، اشخاص دور، چراغ‌های راهنمایی و خودروهای انتهای صف، نمونه‌های متداول این دسته‌اند. دو راهکار متداول برای مقابله با این چالش، افزایش تفکیک‌پذیری ورودی و به‌کارگیری سازوکارهای چندمقیاسی و توجه است. بلوک C2PSA در معماری YOLOv11 با تقویت توجه مکانی، به پالایش ویژگی‌های ناحیه‌ای کمک می‌کند [۵، ۶].

۱-۶-۴- نویز برچسب

در مجموعه داده‌های بزرگ که با رویکردهای نیمه‌نظارتی^۱ برچسب‌گذاری می‌شوند، وجود مقداری نویز اجتناب‌ناپذیر است. این خطاها می‌توانند به صورت کادرهای جاافتاده، کادرهای اضافی یا برچسب رده نادرست بروز کنند. نویز برچسب، هم بر فرایند آموزش اثر می‌گذارد و هم سقف کارایی قابل‌دستیابی را محدود می‌کند؛ زیرا مدل در زمان ارزیابی با مرجعی مقایسه می‌شود که خود کاملاً بی‌خطا نیست [۱۲]. افزون بر این، برخی روش‌های افزایش داده، تصاویر و برچسب‌های آن‌ها را با یکدیگر ترکیب می‌کنند و بر این فرض استوارند که برچسب‌ها دقیق‌اند [۷]. از این رو سودمندی چنین روش‌هایی روی داده‌های نویزدار قطعی نیست و باید به صورت تجربی سنجیده شود؛ ملاحظه‌ای که انگیزه یکی از آزمایش‌های فصل سوم بوده است.

۱-۷- جمع‌بندی

این فصل، مبانی نظری لازم برای بخش‌های بعد را فراهم کرد. بررسی دو خانواده اصلی آشکارسازها نشان داد که روش‌های یک‌مرحله‌ای، به دلیل حذف مرحله پیشنهاد ناحیه، برای کاربردهای بلادرنگ مانند رانندگی خودکار مناسب‌اند. معماری مورد استفاده نیز با بلوک‌های بهبودیافته و سازوکار توجه مکانی، توانایی مناسبی در تشخیص اشیای کوچک دارد. در ادامه، میانگین دقت متوسط به عنوان معیار اصلی ارزیابی معرفی شد و مجموعه داده، شیوه برچسب‌گذاری نیمه‌نظارتی و چهار چالش نشت داده، عدم توازن رده‌ها، اشیای کوچک و نویز برچسب بررسی شدند. فصل دوم به روش انجام پژوهش، آماده‌سازی داده و پیکربندی آموزش می‌پردازد و نحوه مدیریت این چالش‌ها را شرح می‌دهد.

^۱ Semi-supervised

فصل دوم – روش تحقیق، داده و ابزارها

فصل پیشین به مبانی نظری تشخیص اشیا و معیارهای ارزیابی اختصاص داشت. این فصل، روش اجرای پروژه را با جزئیات لازم برای بازتولید آن شرح می‌دهد. بحث با معرفی مدل منتخب و دلایل انتخاب آن آغاز می‌شود و با بررسی مجموعه داده، چالش‌های موجود و فرایند آماده‌سازی نسخه نهایی ادامه می‌یابد. بخش‌های بعد به راهبرد افزایش داده، محیط پیاده‌سازی و پیکربندی آموزش اختصاص دارند و در پایان، شیوه ارزیابی مدل توضیح داده می‌شود.

۲-۱- مدل انتخابی

همان‌گونه که در فصل نخست بیان شد، خانواده YOLO به دلیل ساختار یک مرحله‌ای، تعادل مناسبی میان دقت و سرعت برقرار می‌کند و برای کاربردهای بلادرنگ مانند رانندگی خودکار گزینه‌ای مناسب است. در این پروژه، نسخه یازدهم این خانواده انتخاب شد که در زمان انجام کار، به‌روزترین نسخه پایدار به‌شمار می‌رفت [۶].

این معماری در پنج مقیاس مختلف عرضه می‌شود که از نظر تعداد پارامتر و بار محاسباتی با یکدیگر تفاوت دارند. در این پروژه، مقیاس کوچک، یعنی YOLOv11s با حدود ۹٫۴ میلیون پارامتر انتخاب شد [۶]. دلیل این انتخاب، محدودیت حافظه پردازنده گرافیکی در محیط رایگان مورد استفاده بود؛ مقیاس متوسط این معماری با حدود ۲۰ میلیون پارامتر، حافظه‌ای بیش از ظرفیت در دسترس اشغال می‌کرد و ناچاراً، می‌بایست اندازه دسته^۱ تا یک‌سوم کاهش می‌یافت که خود بر کیفیت آموزش اثر منفی می‌گذاشت. بنابراین مقیاس کوچک، نقطه تعادل میان ظرفیت مدل و محدودیت سخت‌افزاری در نظر گرفته شد.

افزون بر این، فرایند پروژه با استفاده از وزن‌های از پیش آموزش‌دیده روی مجموعه داده COCO آغاز شد. این راهبرد که یادگیری انتقالی^۲ نامیده می‌شود، سبب می‌گردد لایه‌های ابتدایی شبکه که ویژگی‌های عمومی مانند لبه و بافت را استخراج می‌کنند، از ابتدا آموزش نبینند و تنها با داده هدف تنظیم دقیق^۳ شوند. این امر هم زمان آموزش را کاهش می‌دهد و هم در شرایطی که حجم داده محدود است، دقت نهایی را بهبود می‌بخشد [۶].

۲-۲- مجموعه داده

۲-۲-۱- معرفی مجموعه داده

داده مورد استفاده در این پروژه، مجموعه داده رانندگی خودکار ایران با نام اختصاری IADD است [۱]. این مجموعه ۹۷۵۲۸ تصویر را در بر می‌گیرد و شش رده شیء متداول در حوزه خودروهای خودران را پوشش می‌دهد؛ با این حال، در نسخه‌ای که برای دریافت در دسترس بود، تنها ۸۳۰۴۲ تصویر فایل برچسب داشتند و

^۱ Batch Size

^۲ Transfer Learning

^۳ Fine-tuning

۱۴۰۴۸۶ تصویر بخش آزمون بدون برچسب عرضه شده بودند. بنابراین داده‌ای که این پروژه می‌توانست از آن استفاده کند، همان ۸۳۰۰۴۲ تصویر برچسب‌دار است. ویژگی متمایزکننده این مجموعه نسبت به نمونه‌های مشابه، تنوع دامنه آن است؛ تصاویر این مجموعه، شرایط گوناگونی مانند محیط شهری و برون‌شهری، آب‌وهوای نامساعد و جریان‌های ترافیکی متفاوت را شامل می‌شود. همین تنوع، آن را برای سنجش توانایی تعمیم مدل مناسب می‌سازد.

رده‌های این مجموعه داده عبارت‌اند از: شخص، خودروی سبک، موتورسیکلت، اتوبوس، خودروی باری و چراغ راهنمایی. داده به صورت دنباله‌های ویدیویی گردآوری شده است؛ یعنی تصاویر هر ویدیو، فریم‌های متوالی یک مسیر رانندگی می‌باشند. این نکته، چنان‌که در ادامه تشریح می‌شود، در طراحی روش تقسیم داده نقشی تعیین‌کننده دارد.

فهرست شش رده‌ای که در عنوان مصوب این پروژه آمده است، یعنی عابر، تریلر، اتوبوس، خودروی سبک، وانت و موتور، با رده‌های مجموعه داده IADD به طور کامل یکی نیست و توضیح این تفاوت لازم می‌باشد. عنوان پروژه در جلسه‌ای تصویب شد که در آن بازه، اینترنت در کشور قطع بود و جست‌وجو و تحقیق درمورد مجموعه داده‌ها امکان نداشت. از این رو، فهرست رده‌ها بر پایه شناخت عمومی از صحنه ترافیکی ایران تعیین شد، نه بر اساس رده‌های موجود در مجموعه داده‌های در دسترس.

پس از کاهش محدودیت‌های اینترنت، دو مجموعه داده BDD100K و IADD به عنوان گزینه‌های در دسترس شناسایی شدند و با هماهنگی استاد راهنما، IADD به دلیل تطابق دامنه آن با صحنه‌های رانندگی ایران انتخاب گردید. این مجموعه تنها همان شش رده‌ای را برچسب‌گذاری کرده که قبل‌تر به آن اشاره کردیم و رده مستقلی برای تریلر یا وانت ندارد؛ نزدیک‌ترین معادل تریلر در آن، رده عام‌تر خودروی باری است. در مقابل، رده چراغ راهنمایی را نیز در بر می‌گیرد که در فهرست اولیه نبود.

۲-۲-۲- چالش‌های مجموعه داده

بررسی دقیق داده خام، چهار چالش را آشکار کرد که هر یک می‌توانست اعتبار نتایج را خدشه‌دار کند. شناسایی و رفع این چالش‌ها، بخش مهمی از کار عملی این پروژه را تشکیل می‌دهد.

۲-۲-۲-۱- نشت داده میان بخش‌ها

نخستین و مهم‌ترین چالش، نشت داده است. از آنجا که داده از دنباله‌های ویدیویی می‌آید، دو فریم پشت‌سرهم تفاوت بسیار اندکی با یکدیگر دارند. اگر تقسیم به صورت تصادفی و در سطح تصویر انجام پذیرد، فریم‌های نزدیک به هم میان آموزش و ارزیابی پخش می‌شوند. آنگاه مدل روی تصویری سنجیده می‌شود که نمونه‌ای تقریباً یکسان از آن را پیش‌تر دیده است؛ در نتیجه معیارهای گزارش‌شده به‌طور مصنوعی بالا می‌روند، بی‌آنکه چیزی بر توانایی تعمیم افزوده شده باشد.

راهکار این پروژه، تقسیم در سطح کل ویدیو است: هر ویدیوی یکپارچه به یکی از سه بخش آموزش، اعتبارسنجی یا آزمون می‌رود و هرگز میان دو بخش پخش نمی‌شود. بدین ترتیب، مجموعه آزمون تنها از مسیرهایی تشکیل می‌شود که مدل هیچ فریمی از آن‌ها را در فرایند آموزش ندیده است؛ بنابراین، نتایج حاصل از ارزیابی روی این مجموعه، سنجش واقعی‌تری از توانایی مدل در تعمیم به داده‌های تازه ارائه می‌کنند.

۲-۲-۲-۲- ویدیوهای تکراری

چالش دوم، وجود ویدیوهایی با محتوای یکسان اما شناسه متفاوت در مجموعه داده خام بود. چنین ویدیوهایی حتی با رعایت تقسیم در سطح ویدیو نیز می‌توانند نشت ایجاد کنند؛ زیرا ممکن بود یکی از این ویدیوها در بخش آموزش و نسخه دیگر آن در آزمون قرار بگیرد. برای شناسایی این موارد از روش درهم‌سازی

ادراکی^۱ استفاده شد. در این روش، برای هر تصویر یک اثر انگشت کوتاه محاسبه می‌شود که در برابر تغییرات جزئی مانند فشرده‌سازی پایدار است؛ سپس ویدیوهایی که اثر انگشت فریم‌هایشان با یکدیگر شباهت بالایی دارد، به‌عنوان نسخه‌های تکراری علامت‌گذاری می‌شوند. از هر جفت تکراری، تنها یک نسخه در مجموعه نهایی نگه داشته شد [۱۳].

۲-۲-۳- نويز برچسب

چالش سوم، کیفیت برچسب‌ها است. چنان‌که در مرجع [۱] بیان شده، بخشی از برچسب‌های این مجموعه به‌صورت دستی و بخش بزرگ‌تری به‌صورت نیمه‌خودکار و با کمک یک شبکه از پیش آموزش‌دیده تولید شده‌اند. این شیوه، ناگزیر مقداری خطا در برچسب‌ها وارد می‌کند. برای سنجش میزان این خطا، ارزیابی جداگانه‌ای در سطح تک‌تک ویدیوها انجام شد؛ بدین صورت که دقت مدل برای فریم‌های هر ویدیو به‌طور مستقل محاسبه گردید. این تحلیل نشان داد که دو ویدیو نتایج بسیار ضعیفی دارند و با بازبینی چشمی، وجود برچسب‌های ناقص یا نادرست در آن‌ها تأیید شد. این ویدیوها از مجموعه نهایی کنار گذاشته شدند.

لازم به تأکید است که این حذف، تنها بر پایه شواهد مربوط به کیفیت برچسب و پیش از ارزیابی نهایی انجام گرفت و هیچ ویدیویی بر مبنای پایین یا بالا بودن نمره مدل حذف نشد؛ چراکه چنین کاری، اعتبار ارزیابی را از میان می‌برد.

۲-۲-۴- ناهم‌ترازی دشواری بخش‌های ارزیابی

چالش چهارم، برخلاف سه مورد پیشین، به خود داده مربوط نیست؛ بلکه به شیوه تقسیم آن بازمی‌گردد. حتی وقتی تقسیم در سطح کل ویدیو انجام پذیرد و هیچ نشتی وجود نداشته باشد، اگر ویدیوها به‌صورت


^۱ Perceptual Hashing

تصادفی و بدون سنجش دشواری‌شان میان دو بخش اعتبارسنجی و آزمون پخش شوند، ممکن است یکی از دو بخش به‌طور تصادفی صحنه‌های دشواری را در خود جای دهد. در این حالت، دو عددی که از یک مدل واحد به‌دست می‌آید، ممکن است اختلاف زیادی با یکدیگر داشته باشند و تفاوت میان آن‌ها را نمی‌توان به رفتار مدل نسبت داد.

در یکی از نسخه‌های اولیه و آزمایشی این پروژه، همین اتفاق افتاد و فاصله میان دو بخش به حدود سیزده درصد رسیده بود؛ اختلافی که با هیچ تفاوت طبیعی میان دو مجموعه ویدیو قابل توجیه نبود. راهکار به‌کاررفته، بازتقسیم داده با هم‌تراز کردن توزیع اندازه اشیا، توزیع رده‌ها و شرایط محیطی میان دو بخش بود. شواهد این هم‌ترازی در بخش «اعتبارسنجی توزیع داده» ارائه می‌شود و اثر آن بر شکاف میان دو بخش، در فصل چهارم بررسی می‌گردد.

۲-۳- ساخت نسخه نهایی داده

بر پایه چهار چالش ذکرشده، نسخه نهایی مجموعه داده ساخته شد. مراحل این فرایند به ترتیب عبارت‌اند از: حذف ویدیوهای تکراری و ویدیوهای دارای برچسب معیوب؛ تقسیم داده در سطح کل ویدیو با هم‌تراز کردن دشواری دو بخش ارزیابی؛ و در نهایت، برگزیدن شماری از فریم‌های هر بخش تا حجم مجموعه به اندازه قابل آموزش با منابع در دسترس برسد. در گام نهایی، برای رده‌های کم‌نمونه سیاست نگه‌داشت کامل اعمال شد؛ یعنی فریم‌های حاوی این رده‌ها تا حد امکان حفظ شدند تا عدم توازن داده تشدید نشود. شکل (۲-۱) این مراحل را به‌ترتیب نشان می‌دهد.



شکل ۱-۲: مراحل ساخت نسخه نهایی مجموعه داده از داده خام (بخش ۳-۲-۲)

جدول (۱-۲) تعداد تصاویر اختصاص یافته به هر یک از سه بخش آموزش، اعتبارسنجی و آزمون را نشان می‌دهد. از نظر تعداد تصاویر، سهم این سه بخش به ترتیب حدود ۷۰٪، ۱۵٪ و ۱۵٪ درصد از کل داده‌ها است. با این حال، تقسیم داده بر اساس تصاویر انجام نشده است؛ بلکه هر ویدیو به صورت یکپارچه به یکی از سه بخش اختصاص یافته و تمامی فریم‌های آن در همان بخش قرار گرفته‌اند.

جدول ۱-۲: حجم بخش‌های مجموعه داده نهایی

بخش	شمار ویدیو	شمار تصویر	سهم تصاویر	شمار نمونه	نمونه در تصویر
آموزش	۷۹	۲۶,۰۰۰	۷۰٪	۲۰۴,۰۰۹	۷,۸
اعتبارسنجی	۳۹	۵,۵۷۱	۱۵٪	۳۶,۸۱۰	۶,۶
آزمون	۴۲	۵,۵۷۱	۱۵٪	۳۴,۹۹۴	۶,۳


۲-۲-۴- اعتبارسنجی توزیع داده

برای آنکه ارزیابی نهایی قابل دفاع باشد، باید نشان داد که بخش‌های اعتبارسنجی و آزمون از نظر آماری هم‌تراز هستند. سه محور برای این بررسی در نظر گرفته شد: توزیع رده‌ها، توزیع اندازه اشیا و توزیع شرایط محیطی.

جدول (۲-۲) شمار نمونه هر رده را در سه بخش نشان می‌دهد. چنان‌که پیداست، رده خودروی سبک بیشترین سهم و رده‌های اتوبوس و موتورسیکلت کمترین سهم را دارند. این عدم توازن، ویژگی ذاتی داده‌های ترافیکی واقعی است. همین سهم‌ها در شکل (۲-۲) به صورت نموداری آمده است.

جدول ۲-۲: شمار نمونه هر رده در بخش‌های مختلف

آزمون	اعتبارسنجی	آموزش	رده
۲,۴۱۴	۲,۵۱۷	۱۵,۴۵۷	شخص
۲۹,۲۰۳	۳۰,۹۱۰	۱۷۳,۱۹۳	خودروی سبک
۵۱۹	۵۳۱	۱,۷۵۷	موتورسیکلت
۳۲۳	۲۶۵	۱,۰۲۲	اتوبوس
۱,۲۰۶	۱,۲۰۶	۵,۲۳۱	خودروی باری
۱,۳۲۹	۱,۳۸۱	۷,۳۴۹	چراغ راهنمایی
۳۴,۹۹۴	۳۶,۸۱۰	۲۰۴,۰۰۹	مجموع



شکل ۲-۲: سهم هر رده از نمونه‌های هر بخش (محور عمودی لگاریتمی) (بخش ۲-۴)


محور دوم، توزیع اندازه اشیا است که چنان‌که در فصل نخست اشاره شد، عامل اصلی دشواری، تشخیص به‌شمار می‌رود. در این بررسی، اشیایی که مساحت کادر آن‌ها کمتر از یک درصد مساحت تصویر است کوچک، میان یک تا شش درصد متوسط و بیش از شش درصد بزرگ در نظر گرفته شدند.

جدول ۳-۲: توزیع اندازه اشیا در بخش‌های مختلف (درصد)

اندازه شیء	آموزش	اعتبارسنجی	آزمون
کوچک	۷۵٫۵	۷۵٫۱	۷۴٫۷
متوسط	۱۸٫۱	۱۷٫۳	۱۸٫۲
بزرگ	۶٫۴	۷٫۷	۷٫۱

نتیجه این جدول اهمیت زیادی دارد: در هر سه بخش، حدود سه‌چهارم اشیا در رده کوچک قرار می‌گیرند و اختلاف میان بخش اعتبارسنجی و آزمون کمتر از یک درصد است. بنابراین این دو بخش از نظر دشواری

هم‌تراز هستند و مقایسه معیارهای آن‌ها معنادار است. افزون بر این، درصد بالای اشیای کوچک نشان می‌دهد که این مجموعه‌داده ذاتاً دشوار است. شکل (۳-۲) همین توزیع را برای سه بخش کنار هم می‌گذارد.



شکل ۳-۲: توزیع اندازه اشیاء در سه بخش مجموعه‌داده (بخش ۲-۴)

محور سوم، شرایط محیطی است. در مجموعه‌داده IADD، فریم‌های هر ویدیو در یک پوشه جداگانه قرار دارند که انتهای نام آن‌ها، یکی از حروف D، N، R، A نوشته شده‌است. این حروف به ترتیب معادل واژه‌های روز، شب، بارانی و روز ابری هستند. دسته‌بندی این محور براساس همین حروف انجام شد. جدول (۴-۲) سهم هر وضعیت آب‌وهوایی را نشان می‌دهد.

جدول ۲-۴: توزیع شرایط محیطی در بخش‌های مختلف (درصد)

شرایط	آموزش	اعتبارسنجی	آزمون
روز	۸۲٫۴	۸۳٫۶	۷۱٫۷
شب	۷٫۶	۸٫۱	۱۵٫۳
باران	۸٫۹	۷٫۸	۹٫۷
روز آبری	۱٫۲	۰٫۵	۳٫۲

هر سه بخش، همه شرایط را در بر می‌گیرند. سهم تصاویر شبانه در بخش آزمون اندکی بیشتر است که ناشی از شمار محدود ویدیوهای شبانه در کل مجموعه می‌باشد. با این حال، از آنجا که توزیع اندازه اشیا عامل اصلی دشواری است، این تفاوت تنها اثر جزئی بر نتیجه مقایسه دارد. این نکته در فصل چهارم دوباره بررسی خواهد شد. شکل (۲-۴) توزیع شرایط محیطی را نشان می‌دهد.



شکل ۲-۴: توزیع شرایط محیطی در سه بخش مجموعه داده (محور عمودی لگاریتمی) (بخش ۲-۴)

سرانجام، یک بررسی برنامه‌نویسی شده تأیید کرد که اشتراک ویدیوها و تصاویر میان سه بخش دقیقاً صفر است؛ یعنی هیچ فریمی به‌طور هم‌زمان در دو بخش حضور ندارد. در نتیجه، مجموعه داده نهایی معتبر و فاقد نشت اطلاعات می‌باشد.

۲-۳- افزایش داده

افزایش داده مجموعه‌ای از تبدیل‌های تصادفی است که در حین آموزش بر تصاویر ورودی اعمال می‌شود تا مدل تنوع داده بیشتری را تجربه کند و کمتر دچار بیش‌برازش گردد [۶].^۱ تبدیل‌های به‌کاررفته در این پروژه و دلیل انتخاب هر یک، در ادامه شرح داده می‌شود.

نخستین تبدیل، موزاییک است که چهار فریم را در قالب یک تصویر ترکیبی کنار هم قرار می‌دهد. این روش نخستین‌بار در نسخه چهارم YOLO به‌کار گرفته شد [۵]. استفاده از موزاییک سبب می‌شود مدل در هر گام آموزشی با زمینه‌های متنوع‌تری روبه‌رو شود و اشیاء در مقیاس‌های گوناگون دیده شوند. با توجه به غلبه اشیاء کوچک در داده این پروژه، این ویژگی اهمیت بالایی دارد.

تبدیل دوم، ترکیب وزنی است که در مرجع [۷] معرفی شده و دو تصویر را با یکدیگر ترکیب می‌کند. همان‌طور که قبلاً گفته شد، برچسب‌های مجموعه داده IADD تا حدی نویزدار هستند. بنابراین مقدار ترکیب وزنی در تنظیمات پروژه کم و برابر ۰.۱ قرار داده شد تا از تشدید نویز جلوگیری شود.

افزون بر این دو، تغییرات رنگی شامل تنظیم فام، اشباع و روشنایی نیز اعمال شد. ضریب روشنایی روی حالت پیش‌فرض، یعنی مقدار ۰.۴ ماند تا مدل در برابر تفاوت شدت نور میان تصاویر روز و شب مقاوم شود. همچنین چرخش تصادفی با دامنه پنج درجه به‌کار گرفته شد تا اثر کج بودن جزئی دوربین، تشخیص شیء باز هم

^۱ Overfitting

دقیق عمل کند. وارونگی افقی، جابه‌جایی و تغییر مقیاس نیز از تبدیل‌های استاندارد این حوزه هستند که فعال باقی ماندند [۶].

نکته پایانی درباره این دو تبدیل آن است که ماهیت مصنوعی تصاویر ترکیبی در دوره‌های پایانی به زیان مدل تمام می‌شود؛ زیرا توزیع تصاویر آموزشی از توزیع تصاویر واقعی فاصله می‌گیرد. کتابخانه اولترالیتیکس^۱ برای این منظور سازوکاری دارد که موزایک را در چند دوره پایانی خاموش می‌کند [۶]؛ اما چون آموزش این پروژه با توقف زودهنگام و پیش از رسیدن به آن نقطه پایان یافت، این سازوکار هرگز فعال نشد. به جای آن، مرحله دومی با ده دوره و با موزایک و ترکیب وزنی خاموش اجرا گردید که شرح آن در فصل سوم می‌آید.

۲-۴- محیط پیاده‌سازی

پیاده‌سازی این پروژه با زبان برنامه‌نویسی پایتون^۲ و بر پایه کتابخانه اولترالیتیکس انجام شد که پیاده‌سازی مرجع معماری YOLO را در اختیار می‌گذارد [۶]. آموزش مدل در محیط ابری رایگان گوگل کولب^۳ و روی پردازنده گرافیکی تسلا تی^۴، با حدود پانزده گیگابایت حافظه انجام شد.

این محیط دو محدودیت مهم بر کار تحمیل کرد. نخست، محدودیت حافظه پردازنده گرافیکی که چنان‌که گفته شد، انتخاب مقیاس مدل و اندازه دسته آموزشی را تعیین کرد. دوم، محدودیت زمان اتصال؛ نشست‌های این محیط پس از مدتی قطع می‌شوند و آموزش نیمه‌تمام می‌ماند. برای مقابله با این محدودیت، سازوکاری طراحی شد که وضعیت کامل آموزش را در پایان هر دوره روی فضای ذخیره‌سازی ابری نگه

^۱ Ultralytics

^۲ Python

^۳ Google Colab

^۴ Tesla T4

می‌دارد و در نشست بعدی، آموزش را از همان نقطه ادامه می‌دهد. بدین ترتیب، آموزش‌ها در چند نشست جداگانه به انجام رسیدند.

۵-۲- پیکربندی آموزش

جدول (۵-۲) پیکربندی نهایی آموزش را نشان می‌دهد. این پیکربندی حاصل مجموعه‌ای از آزمایش‌های مقایسه‌ای است که نتایج آن در فصل سوم ارائه می‌شود.

جدول ۵-۲: پیکربندی نهایی آموزش مدل

پارامتر	مقدار
معماری	YOLOv11s
اندازه ورودی شبکه	۱۲۸۰ پیکسل
اندازه دسته	۱۲
بهینه‌ساز	AdamW
نرخ یادگیری اولیه	۰٫۰۰۱
زمان‌بند نرخ یادگیری	کسینوسی
ضریب کاهش وزن	۰٫۰۰۰۵
دوره‌های گرم کردن	۳
بیشینه دوره ^۱ آموزش	۱۵۰ (با توقف زودهنگام)
توقف زودهنگام ^۲	۱۰

^۱ Epoch

^۲ Early Stopping

درباره اندازه ورودی، لازم به توضیح است که این پارامتر بعد بزرگ تر تصویر را تعیین می کند. انتخاب مقدار ۱۲۸۰ حاصل یک مقایسه تجربی بود. در دو اجرای پیشین که هر دو روی نسخه یکسانی از داده و با همان مدل کوچک انجام شدند، افزایش این پارامتر از ۹۶۰ به ۱۲۸۰ پیکسل معیار $mAP@0.5$ را روی بخش اعتبارسنجی از ۰.۷۶۶ به ۰.۸۰۲ رساند؛ یعنی حدود سه و نیم درصد بهبود. برای معیار سخت گیرانه تر $mAP@0.5:0.95$ ، این بهبود حتی بزرگ تر و نزدیک به پنج درصد بود. لازم به ذکر است که افزایش اندازه تصاویر ورودی، کاهش اندازه دسته از ۱۶ به ۱۲ را نیز به دنبال داشت، زیرا حافظه پردازنده گرافیکی اجازه بیش از این را نمی داد.

مقدار ۱۲۸۰ سقف طبیعی زیرمجموعه ساخته شده در این پروژه است. بنابراین، بعد بزرگ تر همه تصاویر دقیقاً همین مقدار می باشد و شبکه، تصویر را بدون تغییر مقیاس و تنها با حاشیه گذاری به ورودی مربعی تبدیل می کند [۶]. افزایش این پارامتر، تنها به بزرگ نمایی همان پیکسل ها می انجامد و جزئیات تازه ای نمی افزاید. لازم به ذکر است که سقف ۱۲۸۰ پیکسل، ویژگی زیرمجموعه پروژه انجام شده است، نه مجموعه داده اصلی. IADD تصاویری تا ۳۸۴۰ در ۲۱۶۰ پیکسل نیز دارد. بنابراین رفتن به تفکیک پذیری بالاتر شدن است، اما مستلزم دسترسی به سخت افزار قوی تر می باشد.

درباره بهینه ساز، دو حالت متداول بررسی شد. حالت نخست، گرادیان کاهشی تصادفی^۱ بود که برای همه وزن ها از یک نرخ یادگیری یکسان استفاده می کند. حالت دوم، AdamW بود که برای هر وزن، نرخ یادگیری جداگانه ای بر پایه تاریخچه گرادیان آن نگه می دارد و همچنین، سازوکار کاهش وزن را به صورت مستقل از گرادیان اعمال می کند [۱۴]. در پیکربندی حالت اول، انتخاب بهینه ساز در حالت خودکار به کتابخانه واگذار شده بود و کتابخانه با توجه به شمار زیاد گام های آموزشی، گرادیان کاهشی تصادفی را برگزید. اما در

^۱ Stochastic Gradient Descent

پیکربندی نهایی، AdamW انتخاب شد؛ زیرا با توجه به وجود نویز در برچسب‌های این مجموعه داده، رفتار تطبیقی این بهینه‌ساز پایدارتر بود و مقایسه تجربی که در فصل سوم ارائه شده است، این موضوع را تأیید می‌کند. زمان‌بند نرخ یادگیری، تعیین می‌کند که این مقدار در طول آموزش چگونه کاهش یابد. در این پروژه از زمان‌بند کسینوسی^۱ استفاده شد که در مرجع [۱۵] معرفی شده است. در این روش، نرخ یادگیری مطابق رابطه (۱-۲) و بر پایه یک منحنی کسینوسی از مقدار اولیه به مقدار پایانی میل می‌کند:

$$lr_t = lr_f + (lr_0 - lr_f) \times \frac{1 + \cos(\frac{\pi t}{T})}{2} \quad (1-2)$$

در این رابطه، مقدار نرخ یادگیری در هر دوره، از روی دو کران اولیه و پایانی، شماره آن و تعداد کل دوره‌ها به دست می‌آید. مزیت منحنی کسینوسی آن است که آهنگ کاهش در انتهای آموزش بسیار کند است؛ بنابراین گام‌های به‌روزرسانی وزن‌ها کوچک و یکنواخت می‌مانند و مدل به جای جهش میان نقاط اطراف کمینه، در همان ناحیه همگرا می‌شود.

سرانجام، سازوکار توقف زودهنگام برای تعیین نقطه پایان آموزش به کار رفت. در این سازوکار، معیار ارزیابی پس از هر دوره روی بخش اعتبارسنجی بررسی می‌شود و چنانچه در ده دوره پیاپی مقدار برازش^۲ بهبود پیدا نکند، آموزش متوقف می‌گردد و بهترین وضعیت ثبت شده به عنوان مدل نهایی انتخاب می‌شود. این کار هم از بیش‌برازش جلوگیری می‌کند و هم در مصرف منابع محاسباتی صرفه‌جویی می‌نماید [۶].

^۱ Cosine Annealing

^۲ Fitness

۲-۶- روش ارزیابی

روش ارزیابی این پروژه بر پایه دو اصل بنا شده است که هر دو برای اعتبار نتایج ضروری‌اند:

اصل نخست، جدایی کامل نقش دو بخش اعتبارسنجی و آزمون می‌باشد. اعتبارسنجی تنها برای انتخاب مدل و تنظیم ابرپارامترها به کار می‌رود و بخش آزمون تنها یک بار و برای گزارش نهایی استفاده می‌شود [۱۶]. اگر انتخاب مدل بر اساس نمره آزمون انجام شود، آن بخش دیگر معیار مستقلی نخواهد بود و نتیجه گزارش شده اعتبار خود را از دست می‌دهد.

اصل دوم، به نحوه گزارش معیارها بازمی‌گردد. معیار اصلی این پروژه، میانگین دقت متوسط در آستانه هم‌پوشانی ۰.۵ است که چنان‌که در فصل نخست تشریح شد، از مساحت زیر منحنی دقت و فراخوانی به دست می‌آید. در کنار آن، معیار سخت‌گیرانه‌تر میانگین‌گیری شده روی آستانه‌های ۰.۵ تا ۰.۹۵ نیز گزارش می‌شود [۹، ۳].

در مقابل، ماتریس درهم‌ریختگی^۱ ذاتاً به یک نقطه کاری^۲ مشخص نیاز دارد؛ زیرا برای ساختن آن باید هر پیش‌بینی یا پذیرفته شود یا کنار برود و حالت میانی وجود ندارد. برای آنکه این انتخاب دلخواه نباشد، آستانه اطمینان مقداری قرار گرفت که امتیاز هماهنگ دقت و فراخوانی را روی اعتبارسنجی بیشینه می‌کرد. سپس، همین آستانه بر بخش آزمون اعمال گردید. بدین ترتیب، نقطه کاری بر پایه بخش اعتبارسنجی انتخاب شد و استقلال بخش آزمون حفظ گردید.

^۱ Confusion Matrix

^۲ Operating Point

۲-۷- جمع‌بندی

در فصل دوم، روش کار پروژه از انتخاب مدل تا شیوه ارزیابی بیان شد. مدل برگزیده، مقیاس کوچک نسخه یازدهم YOLO، با وزن‌های از پیش آموزش‌دیده بود که محدودیت حافظه پردازنده گرافیکی استفاده از آن را ایجاب می‌کرد. سپس، مجموعه‌داده IADD معرفی گردید و چهار چالش آن، یعنی نشت داده، ویدیوهای تکراری، نویز برجسته و ناهم‌ترازی دشواری بخش‌های ارزیابی، هر یک راهکار خود را یافتند. بر پایه همین راهکارها، نسخه نهایی مجموعه‌داده، ساخته و هم‌ترازی بخش‌های اعتبارسنجی و آزمون با شواهد آماری تأیید شد. راهبرد افزایش داده، محیط پیاده‌سازی، پیکربندی آموزش و دو اصل حاکم بر ارزیابی، بخش‌های پایانی فصل را تشکیل دادند. خروجی این فصل، مجموعه‌داده‌ای معتبر با تقسیم‌بندی قابل دفاع، پیکربندی آموزش مشخص و یک چارچوب ارزیابی است که استقلال بخش آزمون را حفظ می‌کند. در فصل بعد، نتایج اجرای این روش و آزمایش‌های مقایسه‌ای ارائه می‌شود.

فصل سوم – اجرا، آزمایش‌ها و نتایج


در فصل پیشین، روش کار و پیکربندی آموزش بیان شد. فصل سوم، نتایج حاصل‌شده را ارائه می‌کند. ابتدا روند آموزش و چگونگی همگرایی مدل بیان می‌شود، سپس آزمایش مقایسه‌ای که به انتخاب پیکربندی نهایی انجامید تشریح می‌گردد و در ادامه، نتایج کمی مدل برگزیده روی دو بخش اعتبارسنجی و آزمون، هم به‌صورت کلی و هم به تفکیک رده، گزارش خواهد شد. در پایان، نمونه‌هایی از خروجی کیفی مدل ارائه می‌شود.

۳-۱- روند آموزش و همگرایی

آموزش مدل با پیکربندی نهایی و با بیشینه ۱۵۰ دوره آغاز شد. سازوکار توقف زودهنگام، این مرحله را پس از ۶۲ دوره متوقف کرد؛ زیرا در ده دوره پیاپی پایانی، بهبودی در معیار ارزیابی برازش مشاهده نشد و بهترین وضعیت ثبت‌شده به دوره پنجاه‌ویکم تعلق داشت. سپس مرحله دومی با ده دوره اجرا شد که در آن، تبدیل‌های موزاییک و ترکیب وزنی خاموش بودند تا مدل با توزیع واقعی تصاویر منفرد سازگار گردد؛ بنابراین

مجموع آموزش ۷۲ دوره به طول انجامید. این مرحله دوم روی بخش اعتبارسنجی به ۰٫۸۴۷ رسید، یعنی اندکی پایین‌تر از ۰٫۸۴۹ مرحله نخست؛ از این رو وضعیت دوره پنجاه و یکم به عنوان مدل نهایی باقی ماند.

درباره زمان اجرا، لازم به توضیح است که آموزش به دلیل محدودیت زمانی محیط ابری، در چند نشست جداگانه انجام شد و در هر نشست از آخرین وضعیت ذخیره شده ادامه یافت؛ مرحله نخست به تنهایی هشت نشست را در بر گرفت. میانگین زمان تکمیل شدن هر دوره، حدود سی و چهار دقیقه بود و مجموع زمان دو مرحله، با احتساب ارزیابی پس از هر دوره، به حدود چهل و یک ساعت رسید.



شکل ۱-۳: روند تغییرات خطا و میانگین دقت متوسط در طول آموزش (بخش ۱-۳)

شکل (۱-۳) سه نمودار را نشان می‌دهد. دو نمودار نخست، مقادیر تابع خطا^۱ را برای بخش‌های آموزش و اعتبارسنجی نمایش می‌دهند. در هر دو، منحنی خطا به طور یکنواخت کاهش یافته و در دوره‌های پایانی به مقداری تقریباً ثابت رسیده‌اند. نکته مهم آن است که منحنی اعتبارسنجی در هیچ مرحله‌ای صعودی نشده است؛ چرا که صعود منحنی اعتبارسنجی در حالی که منحنی آموزش همچنان نزولی باشد، نشانه شاخص بیش‌برازش به‌شمار می‌رود و نبود آن، سلامت فرایند آموزش را تأیید می‌کند [۱۶].

^۱ Loss Function


نمودار سوم، دو گونه میانگین دقت متوسط را روی بخش اعتبارسنجی نشان می‌دهد. مدل از مقدار حدود ۰.۰۶ در دوره نخست آغاز به کار کرده و طی حدود بیست دوره، به سرعت رشد داشته است. سپس، آهنگ رشد کند شده و منحنی از حدود دوره سی‌ام به بعد تقریباً هموار گشته. این الگو، رفتار مورد انتظار یک آموزش سالم می‌باشد: بهبود سریع در ابتدا و سپس رسیدن به اشباع.

شایان ذکر است که مقدار نسبتاً بالای معیار $mAP@0.5$ در همان دوره نخست، ناشی از شروع آموزش از وزن‌های از پیش آموزش دیده است؛ مدل از ابتدا، شناخت کلی از مفاهیم اشیای ترافیکی داشته و تنها می‌بایست خود را با ویژگی‌های مجموعه داده هدف سازگار می‌کرد.

۳-۲- آزمایش مقایسه‌ای انتخاب بهینه‌ساز

برای انتخاب پیکربندی نهایی، آزمایشی مقایسه‌ای طراحی شد که در آن تنها یک عامل تغییر می‌کند و بقیه شرایط کاملاً یکسان نگه داشته می‌شود. این شیوه سبب می‌گردد اثر مشاهده شده را بتوان به طور قطعی به همان یک عامل نسبت داد.

عامل مورد بررسی، راهبرد بهینه‌سازی بود. در پیکربندی نخست، انتخاب بهینه‌ساز در حالت خودکار به کتابخانه واگذار شد که با توجه به شمار گام‌های آموزشی، گرادیان کاهشی تصادفی را با نرخ یادگیری ۰.۰۰۱ و زمان‌بند خطی برگزید. در پیکربندی دوم، از بهینه‌ساز AdamW با نرخ یادگیری ۰.۰۰۰۱ و زمان‌بند کسینوسی استفاده شد. در هر دو حالت، معماری، اندازه تصویر، اندازه دسته و تمام تنظیمات افزایش داده یکسان بودند. نتایج در شکل (۲-۳) آمده است.



شکل ۲-۳: مقایسه دو راهبرد بهینه‌سازی روی بخش‌های اعتبارسنجی و آزمون (بخش ۲-۳)

قابل مشاهده است که پیکربندی دوم در هر دو بخش عملکرد بهتری داشت. افزون بر این، بررسی نتایج به تفکیک رده نیز نشان داد که این گزینه در تمام شش رده، نتایج برابر یا بهتر داشته است. بر این اساس، گزینه دوم به عنوان پیکربندی نهایی انتخاب شد و تمام نتایج ارائه شده در ادامه این فصل، مربوط به همین مدل می باشد.

لازم به ذکر است که انتخاب میان دو پیکربندی، بر پایه نتیجه اعتبارسنجی انجام گرفت، نه آزمون. چراکه مطابق اصلی که در فصل پیشین بیان شد، بخش آزمون تنها برای گزارش نهایی به کار می رود و دخالت دادن آن در فرایند انتخاب، استقلالش را از میان می برد.

۳-۳- نتایج کمی مدل نهایی

۳-۳-۱- معیارهای کلی

جدول (۳-۱) معیارهای کلی مدل نهایی را روی دو بخش اعتبارسنجی و آزمون نشان می‌دهد.

جدول ۳-۱: معیارهای کلی مدل نهایی

معیار	اعتبارسنجی	آزمون
mAP@0.5	۰٫۸۴۹	۰٫۸۷۴
mAP@0.5:0.95	۰٫۶۸۷	۰٫۷۰۷

دو نکته در این جدول شایان توجه است. نخست آنکه مقدار معیار روی بخش آزمون اندکی بالاتر از بخش اعتبارسنجی است. این تفاوت حدود دو و نیم درصد است. چنان‌که در فصل پیشین نشان داده شد، توزیع اندازه اشیا در این دو بخش تقریباً یکسان است و بنابراین این اختلاف نشانه‌ای از ایراد روش شناختی نیست.

نکته دوم، فاصله میان دو معیار است. معیار سخت‌گیرانه‌تر که روی آستانه‌های هم‌پوشانی ۰٫۵ تا ۰٫۹۵ میانگین گرفته می‌شود، مقداری به مراتب پایین‌تر دارد. این امر طبیعی است؛ زیرا انطباق بسیار دقیق کادر پیش‌بینی شده با کادر واقعی را می‌طلبد و در مجموعه‌ای که سه چهارم اشیای آن کوچک هستند، دستیابی به چنین انطباقی دشوار است.

۳-۳-۲- نتایج به تفکیک رده

بررسی نتایج به تفکیک رده، تصویر دقیق‌تری از رفتار مدل را ارائه می‌دهد. جدول (۳-۲) معیارهای هر رده را روی بخش آزمون نشان می‌دهد. شکل (۳-۳) دو ستون از همین جدول را به صورت نموداری مقایسه می‌کند.

جدول ۳-۲: معیارهای مدل نهایی به تفکیک رده روی بخش آزمون

رده	دقت	فراخوانی	امتیاز F1	AP@0.5	AP@0.5:0.95
شخص	۰٫۷۸۷	۰٫۸۰۰	۰٫۷۹۴	۰٫۸۶۸	۰٫۶۶۴
خودروی سبک	۰٫۸۷۶	۰٫۹۵۰	۰٫۹۱۲	۰٫۹۶۹	۰٫۸۴۹
موتورسیکلت	۰٫۸۰۹	۰٫۹۰۹	۰٫۸۵۶	۰٫۹۲۸	۰٫۶۳۱
اتوبوس	۰٫۸۲۷	۰٫۶۶۷	۰٫۷۳۹	۰٫۷۹۸	۰٫۶۹۷
خودروی باری	۰٫۷۷۱	۰٫۸۲۵	۰٫۷۹۷	۰٫۸۶۷	۰٫۷۸۴
چراغ راهنمایی	۰٫۷۵۰	۰٫۷۵۴	۰٫۷۵۲	۰٫۸۱۳	۰٫۶۱۸



شکل ۳-۳: معیار AP@0.5 و امتیاز F1 به تفکیک رده روی بخش آزمون (بخش ۳-۳-۲)

رده خودروی سبک با اختلاف، بهترین عملکرد را دارد. این نتیجه دور از انتظار نبود. زیرا این رده هم

پرنمونه‌ترین رده مجموعه است و هم اشیای آن معمولاً بزرگ‌تر و در مرکز میدان دید قرار دارند.


رده موتورسیکلت با وجود آنکه یکی از کم‌نمونه‌ترین رده‌ها است، نتایج خوبی کسب کرد. این مشاهده نشان می‌دهد کم‌بودن شمار نمونه، به‌تنهایی عامل تعیین‌کننده دشواری نیست؛ موتورسیکلت از نظر بصری الگوی متمایزی دارد و به‌سختی با رده‌های دیگر اشتباه گرفته می‌شود.

در مقابل، رده اتوبوس ضعیف‌ترین نتایج را دارد؛ به‌ویژه فراخوانی آن. یعنی مدل، بخشی از اتوبوس‌های موجود را تشخیص نمی‌دهد. دو عامل در این نتیجه نقش داشت: نخست، این رده کم‌نمونه‌ترین رده مجموعه است و دوم، اتوبوس از نظر ظاهری شباهت زیادی به خودروی باری دارد؛ هر دو اجسامی بزرگ و جعبه‌مانند هستند و تمایز آن‌ها حتی برای ناظر انسانی نیز در برخی زوایا دشوار است.

رده چراغ راهنمایی نیز نتیجه به نسبت ضعیف‌تری دارد، اما به دلیل متفاوت. این رده کم‌نمونه نیست، بلکه اشیای آن بسیار کوچک‌اند و در تصویر، تنها چند ده پیکسل را اشغال می‌کنند. چنان‌که در فصل نخست بیان شد، اندازه کوچک شیء یکی از دشوارترین چالش‌های این حوزه است.

جمع‌بندی این بخش بدین شکل است که دو عامل متفاوت بر دشواری هر رده اثر می‌گذارند: تشابه بصری با رده‌های دیگر که رده اتوبوس را متأثر کرده است و اندازه کوچک شیء که رده چراغ راهنمایی را تحت تأثیر قرار داده است. پس، تعداد نمونه‌های موجود به‌تنهایی توضیح‌دهنده خوب یا بد بودن نتایج نیست.

۳-۳-۳- منحنی دقت و فراخوانی




شکل ۴-۳: منحنی دقت و فراخوانی مدل نهایی روی بخش آزمون (بخش ۳-۳-۳)

شکل (۴-۳) منحنی دقت و فراخوانی را برای هر رده و برای میانگین کل نشان می‌دهد. چنان‌که در فصل نخست تشریح شد، مساحت زیر هر منحنی شکل (۴-۳)، مقدار $AP@0.5$ آن رده را نشان می‌دهد. منحنی رده خودروی سبک تا فراخوانی‌های بسیار بالا، دقت بالایی نیز دارد. در حالی که منحنی رده اتوبوس زودتر افت می‌کند. این تصویر، نتایج جدول (۲-۳) را تأیید می‌نماید.

۳-۳-۴- ماتریس درهم‌ریختگی

به‌منظور بررسی دقیق‌تر نحوه عملکرد مدل و تحلیل خطاهای طبقه‌بندی، ماتریس درهم‌ریختگی تهیه شد. برای محاسبه این ماتریس، لازم است آستانه مشخصی برای اطمینان پیش‌بینی‌ها تعیین شود. در این پروژه، آستانه

اطمینان بر اساس بیشینه شدن امتیاز F1 در بخش اعتبارسنجی انتخاب شد. مقدار بهینه این آستانه برابر با ۰.۴۰۶ به دست آمد و همین مقدار برای ارزیابی مدل بر روی بخش آزمون نیز مورد استفاده قرار گرفت. شکل (۵-۳) ماتریس حاصل را نشان می‌دهد.



شکل ۵-۳: ماتریس درهم‌ریختگی نرمال‌سازی شده مدل نهایی روی بخش آزمون (بخش ۳-۴)

بررسی ماتریس درهم‌ریختگی نشان می‌دهد که یکی از مهم‌ترین الگوهای خطای مدل، شباهت و درهم‌آمیختگی میان رده‌های اتوبوس و خودروی باری است. این موضوع با نتایج تحلیل‌های ارائه شده در بخش پیشین نیز هم‌خوانی دارد و نشان می‌دهد که مدل در برخی شرایط، تمایز میان این دو رده را با دشواری انجام می‌دهد. الگوی قابل توجه دیگر، مربوط به عدم تشخیص بخشی از اشیای کوچک است. این مسئله به‌ویژه در رده چراغ راهنمایی مشاهده می‌شود، به گونه‌ای که تعدادی از نمونه‌های این رده توسط مدل شناسایی نشده و

به عنوان پس زمینه در نظر گرفته شده اند. نتیجه مذکور نشان می دهد که اندازه کوچک اشیا همچنان یکی از عوامل مؤثر بر کاهش عملکرد مدل است.

در مجموع، نتایج ماتریس درهم ریختگی دو چالش اصلی مدل را برجسته می کند: نخست، تمایز میان رده های دارای شباهت ظاهری، به ویژه اتوبوس و خودروی باری؛ و دوم، تشخیص اشیای کوچک. این دو مورد می توانند به عنوان مهم ترین محورهای بهبود مدل در پژوهش های آینده در نظر گرفته شوند که در فصل چهارم به آن ها پرداخته خواهد شد.

۳-۴- نتایج کیفی

افزون بر معیارهای عددی، خروجی مدل به صورت شهودی نیز بررسی شد تا نوع موفقیت ها و خطاهایی که در مقادیر کلی منعکس نمی شوند، مشخص گردد. برای هر یک از شرایط روز، شب، باران و روز ابری، ابتدا چهار فریم از بخش آزمون در نظر گرفته شد؛ سپس دو فریم با بیشترین تعداد اشیای برجسته خورده، مشروط به تعلق آن ها به ویدیوهای متفاوت، انتخاب شدند. این شیوه امکان بررسی مدل در صحنه های نسبتاً شلوغ و وضعیت های محیطی گوناگون را فراهم کرد.

هر یک از این چهار وضعیت دشواری متفاوتی دارد. در روز آفتابی مرز اشیا روشن است و تراکم خودروهای دور دشواری اصلی است. در شب، افت کنتراست و بازتاب چراغ ها، مرز خودرو و پس زمینه را محو می کند و اشیای کم نور از قلم می افتند. در باران، قطره های روی شیشه و بازتاب سطح خیس جاده به مثبت نادرست می انجامد. در روز ابری نیز کاهش تمایز رنگی میان خودرو و بافت شهری، جداسازی رده های مشابه را دشوارتر می کند.

در شکل‌های (۳-۶) و (۳-۷)، ستون سمت راست برچسب واقعی و ستون سمت چپ خروجی مدل را برای همان فریم نشان می‌دهد و نام شرایط محیطی در کنار هر جفت سطر آمده است. رنگ هر کادر معرف رده آن است و راهنمای رنگ‌ها در پایین شکل آورده شده.



شکل ۳-۶: مقایسه برچسب واقعی و خروجی مدل در شرایط روز و شب (بخش ۳-۴)



شکل ۳-۷: مقایسه برجسب واقعی و خروجی مدل در شرایط باران و روز آبری (بخش ۳-۴)

بررسی نمونه‌ها نشان می‌دهد که مدل در شرایط محیطی مختلف، بخش عمده اشیای ترافیکی را به‌درستی مکان‌یابی و رده‌بندی کرده است. بیشترین کاستی‌ها در فاصله‌های دور، نور ضعیف و هنگام حضور اشیای کوچک مشاهده می‌شوند؛ الگویی که با نتایج کمی رده‌هایی مانند چراغ راهنمایی هم‌خوانی دارد. در مقابل،

مدل در بعضی فریم‌ها اشیایی را شناسایی کرده است که کادر متناظری در برچسب مرجع ندارند. اما بازبینی تصویر، حضور واقعی آن‌ها را تأیید می‌کند. چنین مواردی هنگام محاسبه معیارها مثبت نادرست محسوب می‌شوند، در حالی که منشأ آن‌ها نقص برچسب است. بنابراین بررسی کیفی، هم توانایی مدل در شرایط گوناگون و هم تأثیر کیفیت برچسب‌ها بر نتایج عددی را روشن می‌کند.

۳-۵- جمع‌بندی

در این فصل، روند آموزش و عملکرد مدل نهایی بررسی شد. منحنی‌ها از همگرایی مناسب فرایند آموزش حکایت داشتند و مقایسه کنترل‌شده دو راهبرد بهینه‌سازی، بر پایه نتایج بخش اعتبارسنجی، AdamW همراه با زمان‌بند کسینوسی را به‌عنوان پیکربندی برتر مشخص کرد. مدل حاصل در بخش آزمون به معیار $mAP@0.5$ برابر ۰.۸۷۴ دست یافت؛ با این حال، تحلیل‌های کمی و نمونه‌های کیفی نشان دادند که تشخیص اشیای کوچک و تفکیک رده‌های دارای شباهت ظاهری، همچنان مهم‌ترین منابع خطای مدل هستند و نقص برخی برچسب‌ها نیز بر معیارهای گزارش‌شده اثر می‌گذارد. فصل بعد به تفسیر این یافته‌ها، بررسی محدودیت‌های پروژه و ارائه مسیرهای بهبود اختصاص دارد.

فصل چهارم – بحث، نتیجه‌گیری و پیشنهادها

فصل سوم عملکرد مدل را با معیارهای کمی و نمونه‌های کیفی گزارش کرد. در این فصل، پیامدهای آن‌ها برای اعتبار ارزیابی و بهبود سامانه بررسی می‌شود. بحث از کیفیت تقسیم داده آغاز می‌گردد، سپس اثر تفکیک‌پذیری، راهبرد بهینه‌سازی و منشأ تفاوت عملکرد میان رده‌ها تحلیل می‌شود. در پایان نیز حدود اعتبار یافته‌ها مشخص و مسیرهای ادامه پروژه بر پایه همین محدودیت‌ها پیشنهاد می‌شوند.

۴-۱- تفسیر یافته‌های اصلی

۴-۱-۱- اعتبار ارزیابی در تقسیم‌بندی ویدیومحور داده

مهم‌ترین نتیجه این پروژه به خود عدد نهایی محدود نمی‌شود. داده‌های تصویری IADD از فریم‌های ویدیویی ساخته شده‌اند و در تقسیم آماده آن، فریم‌های یک مسیر می‌توانستند در بخش‌های گوناگون قرار گیرند. چنین وضعیتی باعث می‌شد مدل هنگام ارزیابی با صحنه‌هایی بسیار نزدیک به داده‌های آموزشی روبه‌رو شود. در نتیجه، عملکرد گزارش شده می‌توانست خوش‌بینانه‌تر از عملکرد واقعی مدل باشد و توانایی آن در

مواجهه با مسیرهای کاملاً ندیده را به درستی نشان ندهد. از این رو، تقسیم در سطح کل ویدیو شرط اولیه اعتبار آزمایش‌ها بود؛ هر مسیر فقط به یکی از بخش‌های آموزش، اعتبارسنجی یا آزمون اختصاص یافت.

این اصلاح به تنهایی کافی نبود. ویدیوهای تکراری با شناسه‌های متفاوت می‌توانستند یک صحنه را دوباره وارد محاسبات کنند و نقص شدید برچسب در چند ویدیو نیز ارزیابی را منحرف می‌ساخت. بازبینی انجام شده میان نمونه‌های دشوار و داده‌های معیوب تمایز گذاشت: فقط مواردی کنار گذاشته شدند که خرابی برچسب آن‌ها با مشاهده مستقیم تأیید شده بود و صحنه‌های دشوار، با وجود معیار پایین، در مجموعه باقی ماندند. این تصمیم مانع از آن شد که پاک‌سازی داده به حذف هدفمند نمونه‌های سخت و افزایش مصنوعی نتیجه تبدیل شود.

پس از حذف موارد تکراری و معیوب، توزیع اندازه اشیاء، فراوانی رده‌ها و شرایط محیطی در دو بخش ارزیابی هم‌تراز شد. فاصله زیاد معیارهای اعتبارسنجی و آزمون که در نسخه‌های قبلی دیده می‌شد، در نسخه نهایی به حدود دو و نیم درصد رسید. اگرچه نزدیک بودن نتایج اعتبارسنجی و آزمون به تنهایی برای اثبات یکسان بودن دشواری دو بخش کافی نیست، اما این نتیجه در کنار تحلیل‌های آماری فصل دوم نشان می‌دهد که دو مجموعه از نظر ویژگی‌های داده و سطح دشواری، هم‌ترازی بیشتری پیدا کرده‌اند. بنابراین کاهش بخشی از عدد آزمون را نباید افت کیفیت مدل دانست؛ نتیجه نهایی بر ارزیابی سخت‌گیرانه‌تر و قابل‌دفاع‌تری استوار است.

۴-۱-۲- اثر تفکیک‌پذیری ورودی بر تشخیص اشیای کوچک

حدود سه‌چهارم نمونه‌های زیرمجموعه نهایی در گروه اشیای کوچک قرار می‌گیرند. افزایش اندازه ورودی از ۹۶۰ به ۱۲۸۰ پیکسل، معیار $mAP@0.5$ اعتبارسنجی را از حدود ۰٫۷۶۶ به ۰٫۸۰۲ رساند و بهبود معیار سخت‌گیرانه‌تر $mAP@0.5:0.95$ نیز بیشتر بود. این الگو با ماهیت مسئله سازگار است: شیء کوچک در

ورودی بزرگ‌تر با تعداد پیکسل بیشتری نمایش داده می‌شود و پس از کاهش‌های پیاپی ابعاد نگاشت ویژگی، اطلاعات مکانی بیشتری از آن باقی می‌ماند.

با این حال، این آزمایش یک مقایسه تک‌عاملی کامل نبود، زیرا هم‌زمان با افزایش تفکیک‌پذیری، اندازه دسته از ۱۶ به ۱۲ کاهش یافت. از این رو نمی‌توان تمام بهبود مشاهده‌شده را صرفاً به اندازه ورودی نسبت داد. نتیجه دقیق‌تر آن است که پیکربندی ۱۲۸۰ پیکسلی در محدودیت سخت‌افزاری موجود عملکرد بهتری داشت و شواهدی عملی به سود حفظ جزئیات بیشتر فراهم کرد. باقی ماندن فاصله میان $mAP@0.5$ و $mAP@0.5:0.95$ نیز بیانگر آن است که مکان‌یابی دقیق کادرها، به‌ویژه برای اشیای کوچک، هنوز دشوار است.

۴-۱-۳- مقایسه راهبردها

در آزمایش نهایی، دو راهبرد با داده، معماری، اندازه ورودی و افزایش داده یکسان مقایسه شدند. پیکربندی مبنا انتخاب خودکار کتابخانه را به کار می‌گرفت که به SGD، نرخ یادگیری اولیه ۰.۰۰۱ و کاهش خطی انجامید. در گزینه دوم، AdamW با نرخ اولیه ۰.۰۰۰۱ و زمان‌بند کسینوسی تعیین شد. راهبرد دوم، معیار $mAP@0.5$ را در اعتبارسنجی از ۰.۸۴۶ به ۰.۸۴۹ و در آزمون از ۰.۸۶۷ به ۰.۸۷۴ افزایش داد.

۴-۱-۴- تحلیل عملکرد مدل در رده‌های مختلف

خودروی سبک با $AP@0.5$ برابر ۰.۹۶۹ بهترین نتیجه را به‌دست آورد. مواردی مانند فراوانی داده، ابعاد مناسب در تصویر و الگوی ظاهری نسبتاً پایدار، یادگیری این رده را آسان‌تر کردند. در مقابل، چراغ راهنمایی با وجود تعداد بیشتر نسبت به برخی گروه‌ها، به ۰.۸۱۳ رسید و پایین‌ترین $AP@0.5:0.95$ را داشت. خطای اصلی در این مورد، اشتباه با یک شیء دیگر نبود؛ بسیاری از چراغ‌ها به دلیل اندازه بسیار کوچک اصلاً یافت نمی‌شدند.

موتورسیکلت مثال روشنی از ناکافی بودن شمار داده به عنوان تنها معیار دشواری است. این رده با تعداد آموزشی نسبتاً کم، $AP@0.5$ برابر ۰٫۹۲۸ کسب کرد؛ زیرا شکل ظاهری آن از دیگر گروه‌ها متمایز است. در سوی دیگر، اتوبوس با مقدار ۰٫۷۹۸ ضعیف‌ترین نتیجه را در این معیار داشت. ماتریس درهم‌ریختگی مشخص می‌کند بخشی از اتوبوس‌ها به صورت خودروی باری پیش‌بینی شده‌اند و نرخ موارد ازدست‌رفته آن نیز بالا است. شباهت بدنه‌های بزرگ و جعبه‌مانند، زاویه دید و تنوع اندک تصاویر، این مرز تصمیم را دشوار کرده‌اند. پس فراوانی، اندازه ظاهری و شباهت میان گروه‌ها باید هم‌زمان در تحلیل عملکرد لحاظ شوند. افزایش نمونه برای اتوبوس زمانی مفید است که تصاویر تازه، حالت‌های مرزی آن با خودروی باری را پوشش دهند؛ درحالی‌که بهبود چراغ راهنمایی بیش از هر چیز به حفظ جزئیات مکانی و برچسب‌گذاری کامل نمونه‌های کوچک وابسته است. یک راهکار واحد برای هر دو خطا پاسخ مناسبی نخواهد بود.

۴-۱-۵- نقش کیفیت برچسب در تحلیل خطا

بازبینی نمونه‌های کیفی نشان داد بخشی از کادرهایی که در ارزیابی مثبت نادرست شمرده می‌شوند، در واقع اشیای حاضر در تصویرند که برچسب مرجع ندارند. در چنین حالتی مدل شیء واقعی را یافته است، اما محاسبه خودکار آن را خطا تلقی می‌کند. از طرف دیگر، کادرهای ناقص یا جابه‌جا، می‌توانند هم معیار مکان‌یابی را کاهش دهند و هم آموزش را با هدف نادرست هدایت کنند. این مسئله با شیوه برچسب‌گذاری نیمه‌خودکار بخشی از تصاویر مجموعه داده IADD ارتباط دارد [۱].

این مشاهده به معنای نادیده گرفتن معیارهای کمی نیست؛ بلکه محدوده تفسیر آن‌ها را روشن می‌کند. عدد گزارش‌شده عملکرد مدل را نسبت به برچسب‌های موجود می‌سنجد، نه نسبت به حقیقتی کاملاً بی‌خطا. به همین دلیل، تحلیل خروجی‌ها در کنار mAP و ماتریس درهم‌ریختگی ضروری بود و چند نمونه تصویری فصل سوم برای تشخیص خطای مدل از نقص داده بررسی شدند.

۴-۲- جایگاه نتایج در مقایسه با پژوهش‌های پیشین

بسیاری از پژوهش‌ها YOLOv11 را در سامانه‌های کمک‌راننده و تشخیص وسایل نقلیه به کار گرفته‌اند [۸]. مقایسه این مطالعات از نظر جهت‌گیری روش‌شناختی مفید می‌باشد. برخی بر معماری و سرعت استنتاج تمرکز دارند و برخی عملکرد چند نسخه YOLO را روی داده‌ای مشخص می‌سنجند. با این حال، کنار هم گذاشتن مستقیم اعداد mAP آن‌ها با نتیجه حاضر معتبر نیست؛ نوع داده، تعریف رده‌ها، اندازه تصاویر، شیوه تقسیم، شرایط آموزش و پروتکل ارزیابی یکسان نیست.

در مقاله معرفی IADD نیز نتیجه‌ای برای YOLOv4 گزارش شده است [۱]، اما همان عدد نباید خط مبنای مستقیم این کار قرار گیرد. بخش آزمون نسخه قابل‌دریافت IADD شامل ۱۴۰۴۸۶ تصویر بدون فایل برچسب بود؛ در نتیجه، بازتولید ارزیابی منتشرشده روی همان تصاویر ممکن نشد. زیرمجموعه حاضر از بخش برچسب‌دار داده ساخته شد و تقسیم آن در سطح ویدیو از نو انجام گرفت. افزون بر این، کد، ابرپارامترها و جزئیات کامل نقطه ارزیابی YOLOv4 در دسترس نبودند.

جایگاه اصلی این کار در مقایسه با مطالعات یادشده، توجه هم‌زمان به مدل و اعتبار داده است. خروجی پروژه فقط یک وزن آموزش‌دیده نیست؛ بلکه یک زیرمجموعه با جداسازی ویدیویی، حذف موارد تکراری و معیوب و دو بخش ارزیابی هم‌تراز نیز ساخته شده است. این فرایند سبب می‌شود عملکرد گزارش‌شده، توانایی مدل در مواجهه با مسیرهای دیده‌نشده را با اطمینان بیشتری نشان دهد؛ هرچند تعمیم آن به مجموعه داده‌های دیگر همچنان نیازمند آزمایش مستقل است.

۴-۳- دامنه اعتبار نتایج و محدودیت‌های اجرایی

۴-۳-۱- دامنه داده و ارزیابی

آزمایش‌ها تنها روی داده‌های IADD انجام شدند. این مجموعه، صحنه‌های متنوعی از ایران را در بر می‌گیرد، اما نتیجه آن لزوماً به دورین، شهر یا الگوی ترافیکی دیگری منتقل نمی‌شود. همچنین به‌علت نبود برجسب برای بخش آزمون منتشرشده، زیرمجموعه نهایی از تصاویر برجسب‌دار در دسترس ساخته شد.

۴-۳-۲- طراحی آزمایش‌های مقایسه‌ای

مقایسه راهبردهای بهینه‌سازی با یک بذر ثابت انجام شد و تکرارهای مستقل برای برآورد میانگین و پراکندگی وجود ندارد. از سوی دیگر، AdamW، نرخ یادگیری و زمان‌بند کسینوسی به‌صورت یک بسته تغییر کردند. این طراحی برای انتخاب پیکربندی نهایی پروژه کافی بود، اما برای تعیین اثر دقیق هر جزء یا ارائه حکم کلی درباره بهینه‌سازها کفایت نمی‌کند.

۴-۳-۳- منابع محاسباتی و انتخاب مقیاس مدل

محدودیت حافظه و زمان اتصال در محیط رایگان گوگل کولب، انتخاب YOLOv11s و اندازه دسته ۱۲ را ضروری کرد. مقیاس‌های بزرگ‌تر یا ورودی‌هایی با جزئیات بیشتر بررسی نشدند و توقف زودهنگام نیز برای کنترل زمان آموزش به کار رفت. در نتیجه، آزمایش‌ها بهترین عملکرد ممکن کل خانواده YOLOv11 را تعیین نمی‌کنند؛ آن‌ها کارایی مقیاس کوچک را در منابع در دسترس می‌سنجند.

۴-۳-۴- پوشش و کیفیت برچسب‌ها

تعداد نمونه‌های اتوبوس و موتورسیکلت بسیار کمتر از خودروی سبک است و تنوع محدودتری دارند. همچنین شماری از اشیای موجود فاقد کادر یا دارای برچسب ناقص‌اند. پاک‌سازی انجام‌شده موارد شدید را حذف کرد؛ اما باز برچسب‌گذاری کامل ده‌ها هزار تصویر در محدوده زمانی پروژه عملی نبود. این کاستی هم بر یادگیری رده‌های کم‌نمونه اثر دارد و هم دقت معیارهای ارزیابی را محدود می‌کند.

۴-۴- نتیجه‌گیری

هدف این پروژه، ساخت و ارزیابی یک آشکارساز شش‌رده‌ای برای اشیای ترافیکی در تصاویر IADD بود. پس از اصلاح تقسیم داده و آموزش YOLOv11s، مدل نهایی روی بخش آزمون به $mAP@0.5$ برابر 0.874 و $mAP@0.5:0.95$ برابر 0.707 رسید. این مقادیر، با توجه به جداسازی کامل ویدیوها، بیانگر عملکرد مدل روی مسیرهایی هستند که در آموزش حضور نداشته‌اند.

تمرکز اصلی پروژه این است که نشان دهد کیفیت طراحی ارزیابی، بیشتر از تنظیم مدل اهمیت دارد. جلوگیری از نشت داده، حذف نسخه‌های تکراری، کنار گذاشتن موارد دارای خرابی تأییدشده و هم‌تراز کردن دشواری دو بخش ارزیابی، معنای عدد نهایی را تغییر دادند. در مقابل، جایگزینی راهبرد بهینه‌سازی تنها بهبودی محدود ایجاد کرد. این تفاوت اندازه اثر نشان می‌دهد که در داده‌های ویدیومحور، اصلاح ساختار مجموعه داده می‌تواند از تغییر یک ابرپارامتر یا بهینه‌ساز تعیین‌کننده‌تر باشد.

مدل در تشخیص خودروی سبک و موتورسیکلت عملکرد مناسبی داشت، اما دو الگوی خطا باقی ماند: از دست رفتن اشیای بسیار کوچک و درهم‌آمیختگی گروه‌های مشابه، به‌ویژه اتوبوس و خودروی باری. بر این

اساس، ادامه کار باید بر کیفیت و تنوع برچسب، حفظ جزئیات اشیای کوچک و آزمایش‌های کنترل‌شده‌تر متمرکز شود.

۴-۵- پیشنهاد برای پژوهش‌های آینده

نخست، تکمیل کادرهای جافتاده و افزودن نمونه‌های متنوع برای اتوبوس و خودروی باری در اولویت قرار دارد. برای چراغ راهنمایی و اشخاص دور نیز می‌توان سطح تشخیص با تفکیک‌پذیری بالاتر، برش هم‌پوشان تصویر و خطای کانونی^۱ را آزمود [۳]. بازبینی باید با تأیید انسانی همراه باشد تا داده دشوار با داده معیوب اشتباه نشود.

دوم، بازسازی زیرمجموعه از فایل‌های خام با وضوح بیشتر می‌تواند جزئیات بیشتری از اشیای کوچک نگه دارد. در این آزمایش باید اندازه دسته و سایر ابرپارامترها ثابت بمانند تا اثر تفکیک‌پذیری جداگانه سنجیده شود. سوم، اثر بهینه‌ساز، نرخ یادگیری و زمان‌بند باید جداگانه و با چند بذر تصادفی سنجیده شود. پس از تثبیت پیکربندی، آزمون روی داده‌ای مستقل، اعتبار بیرونی نتیجه را مشخص می‌کند.

^۱ Focal Loss

- [١] Khosravian, A., Amirkhani, A., Masih-Tehrani, M., and Yazdaniyoo, A., *Multi-domain autonomous driving dataset: Towards enhancing the generalization of the convolutional neural networks in new environments*, IET Image Processing, vol. 17, no. 4, 2023, pp. 1253-1266.
<https://github.com/ahv1373/IADD>
- [٢] Kaufman, S., Rosset, S., Perlich, C., and Stitelman, O., *Leakage in Data Mining: Formulation, Detection, and Avoidance*, ACM Transactions on Knowledge Discovery from Data, vol. 6, no. 4, 2012, article 15.
- [٣] Zou, Z., Chen, K., Shi, Z., Guo, Y., and Ye, J., *Object Detection in 20 Years: A Survey*, Proceedings of the IEEE, vol. 111, no. 3, 2023, pp. 257-276.
- [٤] Redmon, J., Divvala, S., Girshick, R., and Farhadi, A., *You Only Look Once: Unified, Real-Time Object Detection*, Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016, pp. 779-788.
- [٥] Sapkota, R., Flores-Calero, M., Qureshi, R., Badgujar, C., Nepal, U., Poullose, A., Zeno, P., Vaddevolu, U. B. P., Khan, S., Shoman, M., Yan, H., and Karkee, M., *YOLO advances to its genesis: a decadal and comprehensive review of the You Only Look Once (YOLO) series*, Artificial Intelligence Review, vol. 58, no. 9, 2025, article 274.
- [٦] Ultralytics, *Ultralytics YOLO Documentation*, Ultralytics Docs, 2024.
<https://docs.ultralytics.com/models/yolo11/>
- [٧] Zhang, H., Cisse, M., Dauphin, Y. N., and Lopez-Paz, D., *mixup: Beyond Empirical Risk Minimization*, Proceedings of the International Conference on Learning Representations (ICLR), 2018.
- [٨] Chaman, M., El Maliki, A., El Yanboiy, H., Dahou, H., Laamari, H., and Hadjoudja, A., *A Real-Time Vehicle Detection System for ADAS in Autonomous Vehicles Using YOLOv11 Deep Neural Network on Embedded Edge Platforms*, Engineering, Technology and Applied Science Research, vol. 15, no. 5, 2025, pp. 28077-28082.
- [٩] Lin, J., Wang, P., Ruan, Y., and Sun, Y., *YOLO11-WLBS: an efficient model for pavement defect detection*, Scientific Reports, vol. 16, article 5284, 2026.
- [١٠] Lin, T.-Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollar, P., and Zitnick, C. L., *Microsoft COCO: Common Objects in Context*, Proceedings of the European Conference on Computer Vision (ECCV), 2014, pp. 740-755.

- [۱۱] Oksuz, K., Cam, B. C., Kalkan, S., and Akbas, E., *Imbalance Problems in Object Detection: A Review*, IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 43, no. 10, 2021, pp. 3388-3415.
- [۱۲] Song, H., Kim, M., Park, D., Shin, Y., and Lee, J.-G., *Learning From Noisy Labels With Deep Neural Networks: A Survey*, IEEE Transactions on Neural Networks and Learning Systems, vol. 34, no. 11, 2023, pp. 8135-8153.
- [۱۳] Monga, V., and Evans, B. L., *Perceptual Image Hashing Via Feature Points: Performance Evaluation and Tradeoffs*, IEEE Transactions on Image Processing, vol. 15, no. 11, 2006, pp. 3452-3465.
- [۱۴] Loshchilov, I., and Hutter, F., *Decoupled Weight Decay Regularization*, Proceedings of the International Conference on Learning Representations (ICLR), 2019.
- [۱۵] Loshchilov, I., and Hutter, F., *SGDR: Stochastic Gradient Descent with Warm Restarts*, Proceedings of the International Conference on Learning Representations (ICLR), 2017.
- [۱۶] Goodfellow, I., Bengio, Y., and Courville, A., *Deep Learning*, MIT Press, 2016, pp. 108-119.